

Clasificación de Candidatos a Exoplaneta Kepler mediante Aprendizaje Supervisado: Regresión Logística, Naive Bayes y Random Forest

Jheison Martinez Bolivar
 Maestría en Inteligencia Artificial
 Universidad de La Salle, Bogotá, Colombia
 jhmartinez07@unisalle.edu.co

Resumen—Este trabajo aborda un problema de clasificación supervisada multiclase sobre el catálogo acumulativo *Kepler Objects of Interest* (KOI) de la NASA (9 564 registros), en el cual cada detección de tránsito debe etiquetarse como **CONFIRMED**, **CANDIDATE** o **FALSE POSITIVE**. Sobre este catálogo se aplicó un criterio explícito de auditoría de variables, excluyendo las columnas `koi_score` y `koi_disposition` por constituir, en la práctica, la respuesta ya calculada por el pipeline automático de vetting de la NASA. Con un conjunto final de 17 variables físicas del tránsito y de la estrella, y tras un preprocesamiento con partición estratificada (80 %/20 %) y escalado estándar, se compararon tres modelos: Regresión Logística multinomial, Naive Bayes Gaussiano y Random Forest. Random Forest obtuvo el mejor desempeño ($Accuracy = 0,8946$, $F1_{ponderado} = 0,8942$), seguido de Regresión Logística ($Accuracy = 0,8245$) y Naive Bayes ($Accuracy = 0,7087$). El análisis por clase revela que la brecha entre modelos se concentra en distinguir **CANDIDATE** de **CONFIRMED** clases con mediciones muy similares, mientras que Regresión Logística y Random Forest identifican la clase **FALSE POSITIVE** con precisión y recall superiores a 0.98 (Naive Bayes también la identifica bien, aunque con un recall algo menor, de 0.92). El cuaderno con la implementación completa se encuentra disponible en Google Colab: <https://colab.research.google.com/drive/1CwdZLlmRgbdxRQh-9fcUeKQ9C-Nceyg?usp=sharing>.

I. INTRODUCCIÓN

LA misión espacial Kepler de la NASA detecta exoplanetas mediante el *método de tránsito*: monitorea el brillo de cientos de miles de estrellas en búsqueda de caídas periódicas de luminosidad, producidas cuando un planeta cruza por delante de su estrella anfitriona [1]. Sin embargo, no toda caída de brillo corresponde a un planeta real: sistemas binarios eclipsantes, tránsitos de fondo o artefactos instrumentales generan señales indistinguibles a primera vista. Por esta razón, cada detección denominada *Kepler Object of Interest* (KOI) recibe un veredicto (`koi_disposition`) tras un proceso de verificación: **CONFIRMED** (planeta confirmado), **CANDIDATE** (aún no confirmado) o **FALSE POSITIVE** (descartado) [2].

Ante el volumen de detecciones que genera la misión, la verificación manual exhaustiva no es escalable. La propia NASA aborda esto con el *Robovetter*, un pipeline automático de reglas heurísticas que produce el catálogo DR25 utilizado en este trabajo [2]; en paralelo, la comunidad astronómica ha explorado clasificadores de aprendizaje automático supervisado como alternativa o complemento a ese tipo de heurísticas. Este trabajo, desarrollado en el marco de la

Maestría en Inteligencia Artificial de la Universidad de La Salle y como continuación de una actividad previa sobre regresión de excentricidad orbital, aborda precisamente ese problema: clasificar automáticamente cada KOI a partir de las características medibles de su señal de tránsito y de su estrella anfitriona.

Se comparan tres algoritmos supervisados de naturaleza distinta: **Regresión Logística** (modelo lineal, usado como referencia base) [3], **Naive Bayes** (modelo probabilístico generativo) [4], y **Random Forest** (ensamble de árboles de decisión) [5]. El objetivo no es únicamente reportar métricas agregadas, sino entender *por qué* un modelo supera a otro a la luz de sus supuestos estadísticos y de la naturaleza del problema.

II. DATOS Y PREPROCESAMIENTO

II-A. Selección del Conjunto de Datos

La elección del dataset definitivo requirió un proceso de descarte. Un primer candidato, *NASA Exoplanet Archive Intelligence*, ofrecía una columna booleana `habitable_zone_flag` como target natural. Sin embargo, al auditar su relación con las demás variables se encontró que *todas* las columnas categóricas de ese dataset incluida `habitable_zone_flag` eran en realidad reglas de binning deterministas sobre columnas numéricas que permanecían en el propio dataset (por ejemplo, `star_type` coincidía exactamente con rangos fijos de `star_temp_k`, y `multi_planet_system` era idéntica a la condición `n_planets > 1` en el 100 % de los casos). Entrenar un clasificador sobre esas variables habría significado que el modelo aprendiera a repetir una fórmula ya calculada, no un patrón real. Este hallazgo motivó migrar al catálogo **Kepler Objects of Interest (KOI)** [6], cuyo target (`koi_disposition`) corresponde a un veredicto de verificación humana/automática genuino y ampliamente documentado en la literatura astronómica [2].

II-B. Análisis Exploratorio y Balance de Clases

El dataset KOI contiene 9 564 registros y 50 columnas, cuyo significado físico está documentado oficialmente por el NASA Exoplanet Archive [7]. La variable objetivo

`koi_disposition` presenta tres clases con un desbalance moderado: FALSE POSITIVE (52.52 %), CONFIRMED (23.98 %) y CANDIDATE (23.50 %). La Figura 1 muestra el porcentaje de valores nulos por columna.

La Figura 2 visualiza esta distribución de clases junto con la matriz de correlación de Pearson entre las 13 mediciones físicas continuas. Esta matriz no es solo descriptiva: revela correlaciones fuertes entre variables como `koi_prad` y `koi_impact` ($r = 0,68$), `koi_depth` y `koi_model_snr` ($r = 0,58$), y `koi_srad` con `koi_slogg` ($r = -0,64$) evidencia empírica directa de que el supuesto de independencia condicional de Naive Bayes (Sección III-B) se viola en la práctica para este conjunto de variables.

La Figura 3 complementa este análisis mostrando la distribución (escala logarítmica) de tres variables clave por clase: relación señal-ruido, radio planetario y profundidad del tránsito. FALSE POSITIVE tiende a valores más dispersos y en mediana más altos en las tres variables, mientras que CANDIDATE y CONFIRMED presentan distribuciones visualmente muy similares entre sí evidencia visual directa de por qué estas dos clases son las más difíciles de separar para los tres modelos (Sección IV).

II-C. Selección de Features y Prevención de Fuga de Información

Aplicando el mismo criterio de auditoría usado para descartar el primer dataset consistente con la literatura sobre fuga de información en aprendizaje automático [8], se excluyeron del conjunto de predictores tres columnas por constituir fuga de información: `koi_score` (la confianza que el propio pipeline automático de vetting de la NASA, el *Robovetter* [2], asignó a cada disposición final; su media es de 0,015 para FALSE POSITIVE frente a 0,90–0,96 para las otras dos clases, es decir, casi separa el target por sí sola), `koi_pdisposition` (una disposición preliminar casi idéntica a la final) y `kepler_name` (solo se asigna una vez confirmado el planeta). También se descartaron los identificadores sin valor físico (`rowid`, `kepid`, `kepoi_name`), las columnas de margen de error de medición y las coordenadas celestes, para mantener el conjunto enfocado en la señal observada.

El conjunto final quedó compuesto por 17 variables: las cuatro banderas de vetting (`koi_fpflag_nt/ss/co/ec`, que al validarse empíricamente no resultaron perfectamente deterministas frente al target) y trece mediciones físicas del tránsito y la estrella (período orbital, tiempo de referencia del tránsito, parámetro de impacto, duración, profundidad, radio planetario, temperatura de equilibrio, insolación, relación señal-ruido del modelo, temperatura estelar, gravedad superficial, radio estelar y magnitud aparente). La definición exacta de cada una de estas columnas puede consultarse en el glosario oficial del NASA Exoplanet Archive [7].

II-D. Preprocesamiento

Tratamiento de valores faltantes. Se optó por eliminar las filas con nulos en las 17 variables seleccionadas, en lugar de imputarlas, por dos razones: (i) representan solo el 3.8 %

del dataset (364 de 9564 filas), una pérdida acotada; y (ii) al tratarse de mediciones astrofísicas independientes entre KOI (cada fila es una estrella/tránsito distinto, sin relación temporal o secuencial entre observaciones), no existe un valor de referencia (media, mediana o similar) que se pueda asumir válido para la observación faltante sin introducir un sesgo artificial ajeno a la física del sistema. Tras esta eliminación se conservaron 9200 de 9564 registros (96.2 %).

Codificación de variables. No fue necesario un paso explícito de codificación: las 17 variables predictoras finales son, o bien continuas de origen numérico (las 13 mediciones físicas), o bien binarias ya codificadas como 0/1 en el propio catálogo (las cuatro banderas de vetting). La variable objetivo `koi_disposition`, aunque categórica, se dejó como texto (CONFIRMED/CANDIDATE/FALSE POSITIVE) sin codificación numérica adicional, ya que los tres clasificadores de `scikit-learn` utilizados aceptan etiquetas de clase en formato `string` directamente [9].

Partición y escalado. La partición se realizó de forma **estratificada** (80 %/20 %, `random_state = 42`) para preservar la proporción original de clases en entrenamiento y prueba, dado el desbalance detectado. Las variables se estandarizaron con `StandardScaler` ($z = \frac{x-\mu}{\sigma}$) para los modelos sensibles a la escala (Regresión Logística, Naive Bayes); `Random Forest` se entrenó sobre las variables sin escalar, dado que su criterio de partición es invariante a transformaciones monótonas de cada variable.

III. METODOLOGÍA

III-A. Regresión Logística Multinomial

Este modelo, la línea base del estudio, calcula para cada KOI una probabilidad de pertenecer a cada una de las 3 clases y elige la más alta. Esa probabilidad se obtiene con la función *softmax*, que simplemente convierte una combinación ponderada de las 17 variables en un número entre 0 y 1 por clase, de modo que las tres probabilidades sumen 1:

$$P(y = k | \mathbf{x}) = \frac{\exp(\mathbf{w}_k^\top \mathbf{x} + b_k)}{\sum_{j=1}^K \exp(\mathbf{w}_j^\top \mathbf{x} + b_j)} \quad (1)$$

Los pesos $\mathbf{w}_k$ (uno por variable y por clase) se ajustan durante el entrenamiento para que esa probabilidad acierte lo más posible en los datos observados [10]. Lo importante de este modelo es que combina las variables de forma **lineal**: no puede representar que el efecto de una variable dependa del valor de otra, por lo que su desempeño se resiente cuando la separación entre clases requiere justamente ese tipo de combinación.

III-B. Naive Bayes Gaussiano

Este modelo invierte la pregunta: en vez de ir directo de las variables a la clase, pregunta “si esta observación fuera de la clase k , ¿qué tan probable sería ver estos valores de x ?” para cada clase, y con el teorema de Bayes convierte esa respuesta en la probabilidad que realmente nos interesa:

$$P(y = k | \mathbf{x}) \propto P(y = k) \prod_{i=1}^n P(x_i | y = k) \quad (2)$$





Figura 1. Porcentaje de valores nulos por variable en el catálogo KOI.

Figura 2. Distribución de clases de `koi_disposition` (izquierda) y correlación de Pearson entre las 13 features físicas continuas (derecha).

El nombre *naïve* (ingenuo) viene de un supuesto fuerte: que, conocida la clase, cada una de las 17 variables se comporta de forma **independiente** de las demás (por eso el producto $\prod$ en vez de una fórmula conjunta más compleja), y que cada variable sigue una campana de Gauss dentro de cada clase. El supuesto de independencia rara vez se cumple con variables físicas correlacionadas (p. ej., profundidad de tránsito y relación señal-ruido, Figura 2), lo cual como se discute en la Sección IV explica en buena medida su desempeño inferior [4].

III-C. Random Forest

Random Forest entrena $B = 100$ árboles de decisión independientes ($n_{estimators} = 100$, $min_samples_leaf = 2$), cada uno sobre una muestra distinta de los datos y usando en cada división solo un subconjunto aleatorio de variables [5]. Cada árbol individual puede equivocarse, pero al final se toma la clase que la mayoría de los B árboles votó:

$$\hat{y} = \text{moda}\{T_1(\mathbf{x}), T_2(\mathbf{x}), \dots, T_B(\mathbf{x})\} \quad (3)$$

A diferencia de los dos modelos anteriores, cada árbol puede decidir una división *condicionada* al valor de otra variable

(por ejemplo, “si el radio es grande, entonces mirar la profundidad”), así que Random Forest no asume independencia entre predictores ni una frontera lineal [11].

III-D. Métricas de Evaluación

Dado el desbalance de clases, no basta con mirar cuántas predicciones acertaron en total (*accuracy*); también se calculó, por cada clase, qué tan confiables (*precision*) y qué tan completas (*recall*) fueron las predicciones, resumidas en un solo número (F_1) [12]:

$$Accuracy = \frac{\text{predicciones correctas}}{\text{total de observaciones}} \quad (4)$$

$$Precision_k = \frac{TP_k}{TP_k + FP_k}, \quad Recall_k = \frac{TP_k}{TP_k + FN_k} \quad (5)$$

$$F1_k = 2 \cdot \frac{Precision_k \cdot Recall_k}{Precision_k + Recall_k} \quad (6)$$

En palabras simples: *precision* responde “de lo que dije que era clase k , ¿cuánto acerté?”; *recall* responde “de lo que realmente era clase k , ¿cuánto logré detectar?”; y F_1 es un promedio entre ambas para no premiar un modelo bueno en una y malo en la otra.




Figura 3. Distribución (escala log) de relación señal-ruido, radio planetario y profundidad del tránsito, por clase de *koi_disposition*.

Adicionalmente, se ejecutó validación cruzada de 5 pliegues (*k*-fold CV): repetir el entrenamiento 5 veces con particiones distintas de los datos, para confirmar que el resultado no dependió de un único reparto de suerte entre entrenamiento y prueba [9].

IV. RESULTADOS Y DISCUSIÓN

La Tabla I resume las métricas ponderadas de los tres modelos, y la Figura 4 las compara visualmente. Vale aclarar que, en un problema multiclase con promedio ponderado por soporte, *Accuracy* y *Recall* ponderado son matemáticamente idénticos (por eso coinciden exactamente en cada columna de la tabla); se muestran ambos por completitud y para que la fila de *Precision* y *F₁* sea comparable, no porque aporten información independiente entre sí.

Cuadro I
MÉTRICAS COMPARATIVAS (PONDERADAS POR SOPORTE) EN CONJUNTO DE PRUEBA Y VALIDACIÓN CRUZADA

Métrica	Reg. Logística	Naive Bayes	Random Forest
Accuracy (Test)	0.8245	0.7087	0.8946
Precision	0.8244	0.8615	0.8939
Recall	0.8245	0.7087	0.8946
F1-score	0.8218	0.6416	0.8942
Accuracy CV-5fold	0,7983 ± 0,0154	0,7078 ± 0,0312	0,8752 ± 0,0500




Figura 4. Comparación de Accuracy, Precision, Recall y F1-score entre los tres modelos.

A primera vista, la Tabla I sugiere que Naive Bayes tiene una *precision* razonable (0.8615), muy cercana a la de Random Forest. Esta cifra agregada es engañosa: al desagregar por

clase mediante el reporte de clasificación, se observa que Naive Bayes obtiene un *recall* de apenas 0,01 para la clase CONFIRMED es decir, casi nunca la predice, volcando esas observaciones hacia CANDIDATE (cuyo recall sube artificialmente a 0,98), mientras que Random Forest logra 0.81 y 0.78 de recall en CONFIRMED y CANDIDATE respectivamente, y Regresión Logística queda en un punto intermedio (0.75 y 0.54). Regresión Logística y Random Forest identifican FALSE POSITIVE con precisión y recall superiores a 0.98; Naive Bayes también la identifica bien, aunque su recall en esta clase (0.92) es notoriamente inferior al de los otros dos. En general, era esperable que las tres identificaran esta clase con relativa facilidad: es la mayoritaria y las cuatro banderas de vetting (*koi_fpflag_**) son indicadores casi directos de descarte.

Esta disparidad por clase, más que el accuracy agregado, es el hallazgo central del experimento y admite una lectura causal ligada directamente a los supuestos de cada modelo:

- **Naive Bayes falla por su supuesto de independencia.** La Ecuación 2 asume que, dada la clase, cada predictor aporta evidencia independiente de los demás. En este dataset esa condición se viola de forma medible (Figura 2): *koi_depth* y *koi_model_snr* correlacionan con $r = 0,58$, y *koi_prad* con *koi_impact* con $r = 0,68$ un tránsito más profundo se traduce, en buena parte de los casos, en una señal más clara respecto al ruido. Cuando la distinción entre dos clases depende precisamente de cómo covarían varias variables a la vez (y no de sus valores marginales), un modelo que ignora esa covarianza pierde la señal más relevante.
- **Una interpretación plausible es que Random Forest se beneficia de modelar interacciones no lineales.** A diferencia de la frontera lineal de la Regresión Logística (Ecuación 1) y de la independencia asumida por Naive Bayes, cada árbol del ensamble puede particionar el espacio de variables condicionando una división a los valores de otra. Esta explicación es consistente con la arquitectura de cada modelo y con la brecha observada, pero este estudio no calculó importancia de variables (*feature_importances_*) ni un análisis de interacción que la confirme directamente; se trata de una hipótesis razonada, no de un hallazgo verificado empíricamente.

- **El accuracy global no es una métrica confiable bajo desbalance de clases.** Con FALSE POSITIVE representando el 52.5 % del dataset y siendo la clase más fácil de identificar, un modelo mediocre en las otras dos clases aún puede reportar un accuracy aparentemente aceptable. Esto refuerza la necesidad de reportar métricas por clase (Ecuaciones 5 y 6) en lugar de basar las conclusiones únicamente en la Ecuación 4.

IV-A. Ejemplo de Inferencia sobre Datos No Vistos

Las métricas agregadas de la Tabla I resumen el desempeño, pero conviene observar el modelo funcionando caso por caso. La Tabla II muestra la predicción de los tres modelos sobre 8 KOI elegidos al azar del conjunto de prueba (`numpy.random.seed(7)`, sin selección manual posterior) es decir, observaciones que ninguno de los tres vio durante el entrenamiento junto con su etiqueta real.

Cuadro II
PREDICCIÓN DE LOS TRES MODELOS SOBRE 8 KOI NO VISTOS EN
ENTRENAMIENTO (CONF.=CONFIRMED, CAND.=CANDIDATE,
F.POS.=FALSE POSITIVE)

Real	Reg. Log.	Naive Bayes	R. Forest
CONF.	CONF.	CAND.	CONF.
F.POS.	F.POS.	F.POS.	F.POS.
CAND.	CONF.	CAND.	CAND.
F.POS.	F.POS.	F.POS.	F.POS.
F.POS.	F.POS.	F.POS.	F.POS.
F.POS.	F.POS.	F.POS.	F.POS.
CONF.	CONF.	CAND.	CONF.
CONF.	CONF.	CAND.	CONF.

Esta muestra pequeña y por lo tanto anecdótica, no estadísticamente representativa por sí sola ilustra de forma muy concreta el patrón ya identificado: en los tres casos donde la etiqueta real es CONFIRMED, Naive Bayes predice CANDIDATE en los tres (su recall de 0,01 para esta clase, reportado en la Sección IV, no es una rareza estadística sino un comportamiento sistemático). Random Forest acierta las 8 de 8; Regresión Logística falla únicamente en el caso CANDIDATE, prediciendo CONFIRMED el tipo de error opuesto al de Naive Bayes. Las cuatro observaciones FALSE POSITIVE son identificadas sin excepción por los tres modelos, consistente con lo discutido sobre las banderas de vetting.

V. CONCLUSIONES

1. **Random Forest es el modelo más adecuado:** supera a Regresión Logística por 7 puntos de accuracy y a Naive Bayes por 18.6, con mejor desempeño específicamente en las dos clases difíciles, CANDIDATE y CONFIRMED.
2. **El límite es también de los datos, no solo de los modelos:** CANDIDATE y CONFIRMED se solapan fuertemente en sus 17 mediciones físicas, por lo que ningún clasificador puede separarlas con precisión perfecta usando únicamente estas variables.

3. **La brecha entre modelos es consistente con sus supuestos estadísticos:** Naive Bayes falla por asumir independencia entre variables correlacionadas, y Regresión Logística por su frontera lineal. Esta lectura no se verificó con un análisis de importancia de variables, por lo que queda como interpretación razonada y no como hallazgo confirmado.
4. **Auditar y descartar variables con fuga de información** (`koi_score`, `koi_pdisposition`) fue tan determinante para el resultado como la elección del algoritmo.
5. **Aplicabilidad práctica:** Random Forest podría usarse para priorizar qué candidatos revisar primero, no para reemplazar la verificación humana.
6. **Reproducibilidad:** cuaderno completo en Google Colab: https://colab.research.google.com/drive/1CwdZLlmRgbdxRQh-_9fcUeKQ9C-Nceyg?usp=sharing.

APÉNDICE

A. Fragmentos de Código Clave

El cuaderno completo y ejecutable está en Google Colab (ver Conclusión 6); esta sección reproduce únicamente los fragmentos centrales para que el método sea legible sin salir del documento.

Selección de features (Sección II-C):

```
TARGET = "koi_disposition"
FEATURES = [
    "koi_fpflag_nt", "koi_fpflag_ss",
    "koi_fpflag_co", "koi_fpflag_ec",
    "koi_period", "koi_time0bk",
    "koi_impact", "koi_duration",
    "koi_depth", "koi_prad", "koi_teq",
    "koi_insol", "koi_model_snr",
    "koi_steff", "koi_slogg",
    "koi_srad", "koi_kepmag",
]
```

Preprocesamiento (partición estratificada y escalado):

```
df = df_raw[FEATURES + [TARGET]].dropna()
y, X = df[TARGET], df[FEATURES]

X_train, X_test, y_train, y_test =
    train_test_split(
        X, y, test_size=0.20, random_state=42,
        stratify=y)

scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)
X_test_sc = scaler.transform(X_test)
```

Entrenamiento y evaluación (Random Forest, el modelo de mejor desempeño; Regresión Logística y Naive Bayes siguen el mismo patrón, cambiando el estimador por `LogisticRegression` o `GaussianNB` y usando `X_train_sc/X_test_sc` en lugar de `X_train/X_test`):

```
rf = RandomForestClassifier(
    n_estimators=100, min_samples_leaf=2,
    n_jobs=-1, random_state=42)
```

```

rf.fit(X_train, y_train)
y_pred_rf = rf.predict(X_test)

acc_rf = accuracy_score(y_test, y_pred_rf)
f1_rf = f1_score(
    y_test, y_pred_rf, average="weighted")
cv_rf = cross_val_score(
    rf, X, y, cv=5, scoring="accuracy")

```

Inferencia sobre datos no vistos (Sección IV-A, Tabla II):

```

np.random.seed(7)
idx_muestra = np.random.choice(
    X_test.index, size=8, replace=False)
X_muestra = X_test.loc[idx_muestra]
X_muestra_sc = scaler.transform(X_muestra)

pred_lr = lr.predict(X_muestra_sc)
pred_nb = nb.predict(X_muestra_sc)
pred_rf = rf.predict(X_muestra)

```

REFERENCIAS

- [1] W. J. Borucki *et al.*, “Kepler planet-detection mission: Introduction and first results,” *Science*, vol. 327, no. 5968, pp. 977–980, 2010.
- [2] S. E. Thompson *et al.*, “Planetary candidates observed by Kepler. VIII. a fully automated catalog with measured completeness and reliability based on data release 25,” *The Astrophysical Journal Supplement Series*, vol. 235, no. 2, p. 38, 2018.
- [3] D. R. Cox, “The regression analysis of binary sequences,” *Journal of the Royal Statistical Society, Series B*, vol. 20, no. 2, pp. 215–242, 1958.
- [4] I. Rish, “An empirical study of the naive Bayes classifier,” in *IJCAI Workshop on Empirical Methods in Artificial Intelligence*, vol. 3, no. 22, 2001, pp. 41–46.
- [5] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [6] NASA, “Kepler exoplanet search results,” <https://www.kaggle.com/datasets/nasa/kepler-exoplanet-search-results>, 2024.
- [7] NASA Exoplanet Science Institute, “Data columns in Kepler objects of interest table,” https://exoplanetarchive.ipac.caltech.edu/docs/API_kepcandidate_columns.html, 2026, doi: 10.26133/NEA4.
- [8] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, “Leakage in data mining: Formulation, detection, and avoidance,” *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, pp. 15:1–15:21, 2012.
- [9] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [10] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York, NY: Springer, 2009.
- [11] J. Amat Rodrigo, “Random forest con python,” https://cienciadedatos.net/documentos/py08_random_forest_python, 2026. [Online]. Available: https://cienciadedatos.net/documentos/py08_random_forest_python
- [12] D. M. W. Powers, “Evaluation: From precision, recall and f-measure to ROC, informedness, markedness and correlation,” *Journal of Machine Learning Technologies*, vol. 2, no. 1, pp. 37–63, 2011.