

Aprendizaje No Supervisado sobre Objetos Celestes del SDSS DR17:

Análisis de Componentes Principales, K-medias y Mezclas Gaussianas

Jheison Martinez Bolivar
 Maestría en Inteligencia Artificial
 Universidad de La Salle, Bogotá, Colombia
 jhmartinez07@unisalle.edu.co

Resumen—Este trabajo aplica aprendizaje no supervisado sobre 100 000 objetos celestes del *Sloan Digital Sky Survey Data Release 17*, con el objetivo de determinar cuánto de la clasificación espectroscópica oficial (GALAXY, STAR, QSO) puede recuperarse únicamente a partir de las cinco magnitudes fotométricas *ugriz*. La etiqueta se apartó desde el inicio y se usó solo como vara de medición externa. Una auditoría de las 18 columnas mediante información mutua con línea base por permutación llevó a excluir *redshift* por fuga de información —el corrimiento al rojo y el tipo espectral se determinan de forma conjunta e inseparable en el mismo ajuste de plantillas— y a excluir *plate*, *MJD* y *run_ID* por corresponder a la logística de observación del propio sondeo. Sobre las cinco bandas se aplicó PCA: dos componentes concentran el 97.4 % de la varianza, pero el componente dominante (PC1, 85.6 % de varianza) es de los menos informativos sobre el tipo (0.068 nats, cuarto de cinco componentes), mientras que PC2 (11.8 % de varianza) es el más informativo (0.294 nats). Esa disociación domina los resultados: K-medias parte los datos exclusivamente a lo largo de PC1 y alcanza $AMI = 0.0473$, mientras que una mezcla gaussiana con covarianza *full* sobre tres componentes alcanza $AMI = 0.2434$. La comparación de *covariance_type* muestra una progresión monótona (*spherical* 0.0490, *tied* 0.0750, *diag* 0.1441, *full* 0.2434) que no se explica con una sola libertad geométrica. El mejor modelo asigna el 85.4 % de los objetos con más del 90 % de certeza pese a un AMI de 0.24: alta confianza y baja correspondencia con la verdad conviven sin contradicción. El cuaderno con la implementación completa está disponible en Google Colab: <https://colab.research.google.com/drive/1vBsjBbquzO43cMjjuuwck8IQBVHYOaMvX?usp=sharing>.

I. INTRODUCCIÓN

EL *Sloan Digital Sky Survey* (SDSS) observa el cielo de dos maneras que cuestan cosas muy distintas. La primera es la **fotometría**: una cámara mide cuánto luz llega de un objeto a través de cinco filtros de colores —*u* (ultravioleta), *g* (verde-azul), *r* (rojo), *i* (infrarrojo cercano) y *z* (infrarrojo)— y produce cinco números por objeto [1]. Es barata y se aplica a todo lo que entra en el campo de visión. La segunda es la **espectroscopía**: se dirige una fibra óptica a un objeto concreto y se descompone su luz en un espectro completo, del cual el *pipeline* del sondeo deriva tanto su tipo (GALAXY, STAR, QSO) como su corrimiento al rojo [2]. Es cara, lenta y limitada a los objetos que se decida apuntar.

Conviene precisar el significado físico de las cinco magnitudes, porque no se comportan como una medición ordinaria: la magnitud astronómica es *logarítmica e invertida*. La escala moderna fija la razón de brillo entre dos magnitudes consecutivas en $100^{1/5} \approx 2,512$ [3], y hereda de los catálogos clásicos el orden invertido, de modo que un número más pequeño corresponde a un objeto más brillante. Su valor absoluto mezcla dos cosas distintas —cuánta luz emite el objeto y qué tan lejos está—, mientras que la *diferencia* entre dos bandas (*u*−*g*, *g*−*r*, ...), llamada *color*, describe la forma del espectro y es en principio independiente de la distancia. Esta distinción entre brillo y color reaparecerá como el eje central de todo el análisis.

El problema que aborda este trabajo es directo: **si solo se tuvieran las cinco magnitudes fotométricas, sin espectro y sin etiqueta, ¿cuánto de la clasificación oficial se podría reconstruir?** La pregunta no es académica: los sondeos fotométricos producen órdenes de magnitud más objetos de los que alcanza a cubrir la espectroscopía, de manera que cualquier estructura recuperable desde la fotometría sola tiene valor práctico para priorizar qué observar.

Se aplican tres técnicas no supervisadas de naturaleza complementaria: **Análisis de Componentes Principales** (PCA) como reducción de dimensionalidad [4], [5], **K-medias** como particionamiento geométrico [6], [7] y **mezclas gaussianas** (GMM) como modelo probabilístico generativo [8], [9]. La etiqueta *class* se apartó antes de tocar los datos y no participó en ningún entrenamiento; se reservó únicamente como *vara de medición externa* mediante información mutua ajustada [10]. El objetivo no es maximizar una métrica, sino entender *qué* estructura encuentra cada algoritmo y *por qué* esa estructura coincide o no con la clasificación física.

II. DATOS Y PREPROCESAMIENTO

II-A. Conjunto de Datos

Se empleó el catálogo *Stellar Classification Dataset SDSS17* [11], una extracción de 100 000 objetos y 18 columnas del *Data Release 17* del SDSS [12]. La variable *class* distribuye los objetos en GALAXY (59 445 objetos, 59.4 %), STAR (21 594, 21.6 %) y QSO (18 961, 19.0 %). No hay valores nulos.

Las 18 columnas provienen de tres orígenes distintos, distinción que resulta central para la selección de variables: siete son fotométricas (las cinco bandas *ugriz* más las coordenadas celestes *alpha* y *delta*), seis son espectroscópicas (*spec_obj_ID*, *class*, *redshift*, *plate*, *MJD*, *fiber_ID*) y el resto son identificadores de la operación del telescopio (*obj_ID*, *run_ID*, *rerun_ID*, *cam_col*, *field_ID*). Es importante consignar una limitación de partida: **el conjunto de datos no incluye un diccionario de columnas**, de modo que esta separación se infirió de los nombres de las variables y del funcionamiento documentado del SDSS [13]. Es una suposición apoyada en el dominio, no una verificación en la fuente.

II-B. Análisis Exploratorio

La auditoría de cardinalidad reveló dos casos degenerados: *rerun_ID* es constante (un único valor en las 100 000 filas, por lo que no puede informar nada) y *spec_obj_ID* toma un valor distinto por fila (es una clave primaria, no una medición).

Las bandas presentan un artefacto de instrumentación: el resumen estadístico muestra mínimos de -9999 en *u*, *g* y *z*, con desviaciones estándar infladas a ~ 31.7 frente a ~ 1.8 en *r* e *i*. Ese valor es un código centinela de medición fallida, no una magnitud. Afecta a **una sola fila** de las 100 000, que se eliminó; el análisis continúa sobre 99 999 objetos.

La Figura 1 muestra la correlación de Pearson entre todas las columnas numéricas. Las cinco bandas forman un bloque fuertemente correlacionado entre sí (nueve de los diez pares superan $r = 0,6$; el máximo es $r = 0,972$ entre *i* y *z*, y el mínimo $r = 0,546$ entre *u* y *z*, los dos extremos del rango de longitudes de onda): un objeto brillante lo es en todas las bandas a la vez. Esta redundancia es exactamente la condición que hace apropiado un PCA. Las coordenadas celestes y los identificadores, en cambio, no correlacionan de forma apreciable con las bandas.

II-C. Auditoría de Variables y Fuga de Información

Descartar variables por intuición es un riesgo, así que la selección se hizo midiendo. Se calculó la **información mutua** entre cada columna candidata y la etiqueta [14], con el estimador por vecinos más cercanos de *scikit-learn* [15], [16]. La información mutua tiene una trampa conocida: una variable con muchos valores distintos obtiene una puntuación alta incluso cuando no guarda ninguna relación real con la etiqueta, simplemente porque cada valor identifica a pocas filas. Es el mismo sesgo por el que la información mutua entre particiones debe corregirse por el acuerdo esperado al azar [10]. Para acotarla se calculó además una **línea base por permutación**: se barajó la etiqueta al azar tres veces y se promedió la información mutua obtenida contra esa etiqueta sin sentido. La diferencia entre la medición real y esa línea base es la señal atribuible. Tres réplicas son pocas para estimar esa línea con precisión, pero basta para lo que se decide con ella. La corrección que aporta es a lo sumo de 0.069 nats (el caso de *plate*, la columna de mayor cardinalidad), entre dos y cuatro veces menor que los excesos sobre los que se sustentan las exclusiones; para el resto de columnas

la desproporción es mucho mayor (*run_ID*: 0.0044 de línea base frente a 0.1432 de exceso). La línea tendría que estar muy mal estimada para alterar el orden. La Figura 2 presenta el resultado, con la entropía de la etiqueta (0.9554 nats) marcada como techo alcanzable.




Figura 2. Información mutua de cada columna con el tipo de objeto. La barra de color es el exceso sobre la línea base por permutación; la barra negra es la inflación atribuible a la cardinalidad.

Tres exclusiones se derivan de esta medición, y ninguna se sostiene en que la variable sea poco informativa —al contrario, las tres están entre las más informativas del catálogo—:

redshift (exceso 0.8014 nats). Concentra el 84 % de la entropía total de la etiqueta: por sí sola casi resuelve el problema. La razón para excluirla no es esa magnitud, sino su procedencia. El *pipeline* espectroscópico del SDSS no mide el corrimiento al rojo y luego, por separado, clasifica el objeto: ajusta simultáneamente pares (plantilla de tipo $\times$ corrimiento) contra el espectro observado y se queda con la combinación de mejor χ^2 [2]. La inseparabilidad es de fondo, no de implementación: para medir cuánto se desplazó una línea espectral hay que saber qué línea es, y para identificarla hay que reconocer el patrón completo, que depende del tipo de objeto. **No se puede medir el corrimiento sin suponer qué tipo de objeto es, ni determinar el tipo sin conocer el corrimiento.** Usar *redshift* como predictor equivaldría a alimentar al modelo con la respuesta ya calculada, el mismo tipo de fuga descrito en la literatura sobre *leakage* [17].

plate (0.2691), MJD (0.1920) y run_ID (0.1432). Superan a la mejor banda fotométrica (*z*, 0.1449, y las tres primeras superan a *g*, *i*, *u* y *r*). No son propiedades del objeto: identifican la placa metálica de fibras ópticas, la fecha juliana modificada de la observación y la pasada del telescopio. Informan porque el sondeo *decide* qué observar y cuándo: una placa dedicada a un programa de cuásares contiene desproporcionadamente cuásares. Es un **efecto de selección** del sondeo, no física del objeto, y un modelo que lo aproveche estaría aprendiendo el calendario del telescopio.

El conjunto final de predictores quedó reducido a las **cinco magnitudes fotométricas** *u*, *g*, *r*, *i*, *z*. Las coordenadas *alpha* y *delta* se excluyeron por la misma razón de selección (informan sobre qué región del cielo se priorizó), y los identificadores restantes por carecer de contenido físico.




Figura 1. Correlación de Pearson entre las columnas numéricas. El bloque de las cinco bandas *ugriz* concentra la redundancia que justifica el PCA.

II-D. Escalado

Las cinco bandas se estandarizaron con `StandardScaler` ($z = (x - \mu)/\sigma$) antes del PCA. Aunque las magnitudes comparten unidad y rango similar, el PCA diagonaliza la matriz de covarianza y por tanto es sensible a la escala de cada variable: sin estandarizar, la banda de mayor varianza dominaría el primer componente por una razón aritmética y no informativa [5].

III. METODOLOGÍA

III-A. Análisis de Componentes Principales

PCA busca un nuevo sistema de ejes, rotación del original, tal que el primer eje capture la mayor varianza posible, el segundo la mayor varianza restante siendo ortogonal al primero, y así sucesivamente. Formalmente, los ejes son los vectores propios $\mathbf{w}$ de la matriz de covarianza Σ de los datos estandarizados:

$$\Sigma \mathbf{w}_j = \lambda_j \mathbf{w}_j, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \quad (1)$$

donde el valor propio λ_j es la varianza capturada por el eje j , y la proporción $\lambda_j / \sum_i \lambda_i$ es la *varianza explicada* [4], [5]. Los coeficientes de cada vector propio (*loadings*) indican cuánto pesa cada variable original dentro del componente, y son lo que permite interpretarlo físicamente.

Debe subrayarse un punto que resulta decisivo en la Sección IV: **PCA maximiza varianza, no separabilidad**. Nada

en la Ecuación 1 involucra la etiqueta, de modo que no existe garantía alguna de que el eje de mayor varianza sea el más útil para distinguir clases.

III-B. K-medias

K-medias parte los datos en k grupos minimizando la suma de distancias euclidianas al cuadrado entre cada punto y el centroide de su grupo [6], [7]:

$$J = \sum_{j=1}^k \sum_{\mathbf{x} \in C_j} \|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \quad (2)$$

El algoritmo alterna dos pasos hasta converger: asignar cada punto al centroide más cercano, y recalculer cada centroide como la media de sus puntos. La consecuencia geométrica de usar distancia euclidiana es que **K-medias supone grupos esféricos y de tamaño comparable**: sus fronteras son hiperplanos equidistantes entre centroides (una teselación de Voronoi). Un grupo genuinamente alargado o inclinado no puede representarse con ese vocabulario.

III-C. Mezcla de Gaussianas

Una mezcla gaussiana modela la densidad de los datos como suma ponderada de k campanas multivariadas [9]:

$$p(\mathbf{x}) = \sum_{j=1}^k \pi_j \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_j, \Sigma_j), \quad \sum_{j=1}^k \pi_j = 1 \quad (3)$$

Los parámetros se ajustan por máxima verosimilitud con el algoritmo EM [8], [18], que alterna entre calcular la probabilidad de que cada punto pertenezca a cada campana (*responsabilidades*) y reestimar medias, covarianzas y pesos con esas probabilidades como ponderación. A diferencia de K-medias, la asignación es **blanda**: cada objeto recibe una distribución de pertenencia, no una etiqueta dura.

La diferencia geométrica de fondo está en la métrica. La pertenencia a una campana no depende de la distancia euclidiana al centro sino de la **distancia de Mahalanobis** [19]:

$$d_M^2(\mathbf{x}, \boldsymbol{\mu}_j) = (\mathbf{x} - \boldsymbol{\mu}_j)^\top \Sigma_j^{-1} (\mathbf{x} - \boldsymbol{\mu}_j) \quad (4)$$

que mide el desplazamiento en unidades de la dispersión propia del grupo *en cada dirección*. Dos puntos a la misma distancia euclidiana del centro pueden estar a distancias de Mahalanobis muy distintas si la campana es alargada. Cuando $\Sigma_j = \sigma^2 I$, la Ecuación 4 se reduce a la distancia euclidiana escalada y la mezcla se comporta como K-medias.

La forma admisible de Σ_j se controla con el parámetro `covariance_type`, que en `scikit-learn` ofrece cuatro variantes crecientes en libertad [16]: `spherical` (una sola varianza por campana), `tied` (una única matriz completa compartida por todas), `diag` (una matriz diagonal por campana, ejes independientes pero alineados con los del espacio) y `full` (una matriz completa por campana, con inclinación propia).

III-D. Métricas de Evaluación

Sin etiqueta no hay *accuracy*, por lo que la evaluación combina tres criterios de naturaleza distinta.

Silhouette (criterio *interno*): mide qué tan compacto y separado quedó cada grupo usando únicamente la geometría de los datos [20]. Para cada punto i , con $a(i)$ la distancia media a los puntos de su propio grupo y $b(i)$ la distancia media al grupo vecino más cercano:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1] \quad (5)$$

Información Mutua Ajustada (criterio *externo*): compara la partición hallada U con la etiqueta real V , corrigiendo por el acuerdo esperado al azar [10]:

$$AMI(U, V) = \frac{MI(U, V) - \mathbb{E}[MI(U, V)]}{\overline{H}(U, V) - \mathbb{E}[MI(U, V)]} \quad (6)$$

Vale 0 cuando la coincidencia es la esperable por azar y 1 cuando las particiones son idénticas. La corrección por azar importa aquí: sin ella, dos particiones cualesquiera con muchos grupos parecen coincidir más de lo que realmente lo hacen.

Criterio de Información Bayesiano (BIC), para elegir entre modelos de la misma familia probabilística [21]:

$$BIC = -2 \ln \hat{L} + p \ln n \quad (7)$$

Penaliza la verosimilitud $\hat{L}$ por el número de parámetros p ; a menor BIC, mejor. Es aplicable a las variantes de GMM entre sí, pero **no** a K-medias, que no define una verosimilitud comparable.

Es indispensable subrayar que el AMI **usa la etiqueta**. En un problema genuinamente sin etiquetar no estaría disponible,

y ese es el límite honesto de este trabajo: se dispone de una vara externa que en la práctica no se tendría.

IV. RESULTADOS Y DISCUSIÓN

IV-A. PCA: la varianza no es la utilidad

El PCA sobre las cinco bandas estandarizadas produce una reducción muy eficiente en términos de varianza: PC1 concentra el 85.63 %, PC2 el 11.77 % y PC3 el 1.86 %, de modo que dos componentes acumulan el 97.40 % y tres el 99.26 % (Figura 3, izquierda).

Los *loadings* (Figura 3, derecha) permiten leer físicamente los dos primeros ejes. En PC1 las cinco bandas pesan con el mismo signo y magnitudes parecidas (entre 0.387 y 0.477): es un promedio de las cinco magnitudes, es decir, **el brillo global del objeto**. En PC2 los signos se separan de forma ordenada por longitud de onda (u : +0,754, g : +0,280, r : -0,107, i : -0,346, z : -0,471): es un contraste entre el extremo azul y el extremo rojo del espectro, es decir, **el color**.

El resultado central del análisis aparece al confrontar varianza con información (Figura 4, izquierda). El componente que acumula el 85.63 % de la varianza queda cuarto de cinco en información mutua con el tipo de objeto ($MI = 0,0677$ nats), mientras que PC2, con apenas el 11.77 % de la varianza, es el más informativo ($MI = 0,2942$ nats, más del cuádruple que PC1). PC3 (1.86 % de varianza) informa 0.0800, también por encima de PC1, e incluso PC4 (0.45 % de varianza) alcanza 0.0861.

La interpretación física de esta disociación es directa y consistente con lo dicho en la Introducción. La mayor fuente de variabilidad en un catálogo fotométrico es el brillo aparente, que depende sobre todo de la distancia: hay objetos cercanos y objetos lejanos de todos los tipos. El color, en cambio, describe la forma del espectro y es lo que distingue físicamente a una estrella de un cuásar. La dispersión de la Figura 4 (derecha) lo confirma visualmente: los tres tipos se solapan ampliamente a lo largo de PC1 y se ordenan, con solapamiento pero de forma perceptible, a lo largo de PC2.

Esta es la advertencia metodológica más importante del trabajo: elegir componentes por varianza acumulada —el procedimiento habitual, y el único disponible sin etiqueta— habría conservado los dos primeros (97.4 %) y descartado precisamente componentes que informan más que el que se conservó primero.

IV-B. Selección de componentes y de k

Con $k = 3$ fijo, el barrido sobre el número de componentes retenidos muestra un comportamiento muy asimétrico entre los dos algoritmos (Tabla I). K-medias es indiferente: su AMI se mantiene plano en $\approx 0,047$ con dos, tres o cuatro componentes. La mezcla gaussiana, en cambio, salta de 0.0584 a 0.2434 al pasar de dos a tres componentes, y vuelve a caer a 0.0548 con cuatro.




Figura 3. Varianza explicada y acumulada (izquierda) y *loadings* de cada banda en cada componente (derecha).




Figura 4. Izquierda: varianza explicada frente a información mutua con el tipo, por componente. Derecha: los tres tipos reales proyectados sobre PC1-PC2 (muestra de 6 000 objetos).

Tabla I

EFFECTO DEL NÚMERO DE COMPONENTES RETENIDOS, CON $k = 3$ FIJO

Componentes	Var. acumulada	AMI K-medias	AMI GMM
2	0.9740	0.0474	0.0584
3	0.9926	0.0473	0.2434
4	0.9972	0.0472	0.0548

Debe declararse con claridad que **la columna que señala a tres componentes como la mejor opción es el AMI, y el AMI se calcula contra la etiqueta**. En un problema realmente sin etiquetar solo se dispondría de la varianza acumulada, se habrían elegido dos componentes, y nunca se habría sabido lo que se perdía. La configuración ganadora se eligió mirando la respuesta.

Para el número de grupos se fijó $k = 3$ por dos razones convergentes: es el número de clases de la etiqueta de referencia, lo que hace comparables las particiones, y los criterios internos no ofrecen una alternativa concluyente (Figura 5). La inercia decrece suavemente sin codo nítido; el silhouette es máximo en $k = 2$ (0.5607) y cae a 0.3800 en $k = 3$; y el BIC de la mezcla decrece de forma monótona hasta $k = 8$ sin encontrar mínimo en el rango explorado. Es decir, ningún criterio interno apunta a tres grupos: la elección se apoya en el conocimiento de la etiqueta, no en la geometría.

IV-C. Qué eje usa realmente cada algoritmo

La diferencia de comportamiento entre los dos modelos se explica al inspeccionar sus centroides. Midiendo el rango que cubren los tres centros en cada eje, K-medias los separa 4.76 unidades en PC1, 0.11 en PC2 y 0.04 en PC3: **parte los datos exclusivamente por brillo**, ignorando el color por completo. Las medias de la mezcla gaussiana, en cambio, se reparten 3.91 en PC1 pero también 1.44 en PC2, un orden de magnitud más que K-medias.

La Tabla II pone a prueba esta lectura entregando a cada algoritmo distintos subconjuntos de ejes. El experimento confirma el diagnóstico: K-medias sobre PC1 solo (0.0478) rinde lo mismo que sobre los tres ejes juntos (0.0473), mientras que K-medias sobre PC2 solo salta a 0.2014. Cuando se le retira PC1 y se le deja PC2+PC3, K-medias alcanza 0.2093, cuatro veces su desempeño con todos los ejes disponibles. **El componente de mayor varianza no solo no ayudaba: activamente estorbaba**, porque su escala domina la distancia euclidiana de la Ecuación 2 y arrastra la partición hacia él.




Figura 5. Criterios para elegir k : inercia de K-medias, silhouette y BIC de la mezcla gaussiana. Ninguno señala $k = 3$.

Tabla II
AMI SEGÚN LOS EJES ENTREGADOS A CADA ALGORITMO

Ejes usados	Var. incl.	K-medias	GMM diag	GMM full
PC1	0.8563	0.0478	0.0456	0.0456
PC2	0.1177	0.2014	0.2012	0.2012
PC3	0.0186	0.0302	0.0268	0.0268
PC1+PC2	0.9740	0.0474	0.0529	0.0584
PC1+PC3	0.8749	0.0484	0.0427	0.0499
PC2+PC3	0.1363	0.2093	0.2095	0.1403
PC1+PC2+PC3	0.9926	0.0473	0.1441	0.2434

La mezcla gaussiana con covarianza *full* sobre los tres componentes es la única configuración que supera lo que se obtiene descartando PC1 a mano: 0.2434 frente a 0.2095, el mejor valor de la fila PC2+PC3. Es decir, **el modelo probabilístico logra convivir con el eje de brillo en lugar de tener que eliminarlo**, porque la Ecuación 4 le permite normalizar internamente la dispersión de cada dirección en vez de sufrirla.

IV-D. El efecto de *covariance_type*

Manteniendo fijos los tres componentes y $k = 3$, variar únicamente la forma admisible de las campanas produce una progresión monótona en el criterio externo (Tabla III): *spherical* 0.0490, *tied* 0.0750, *diag* 0.1441, *full* 0.2434. La variante más restringida es indistinguible de K-medias (0.0473), lo cual es coherente con la teoría: K-medias se obtiene como el límite de una mezcla de gaussianas esféricas cuando la varianza común tiende a cero y las responsabilidades se vuelven duras [22, §9.3.2].

Tabla III
COMPARACIÓN DE COVARIANCE_TYPE CON $k = 3$ Y TRES COMPONENTES

Variante	Paráms.	BIC	Silhouette	AMI
<i>spherical</i>	14	783 501	0.3823	0.0490
<i>tied</i>	17	660 495	0.3271	0.0750
<i>diag</i>	20	604 604	0.3025	0.1441
<i>full</i>	29	570 165	0.3619	0.2434
K-medias (ref.)	—	—	0.3800	0.0473

La Figura 6 muestra el hallazgo más incómodo del experimento: **los dos criterios de evaluación no coinciden**.

El mejor modelo según el silhouette es *spherical*, que es de los peores según el AMI; y *full*, el mejor por AMI, queda segundo por silhouette, por debajo de la variante que peor recupera la estructura real. La explicación es que el silhouette premia grupos compactos y bien separados en distancia euclidiana —exactamente el tipo de partición que produce cortar por PC1—, mientras que la estructura física real vive en un eje de baja varianza. El BIC, en cambio, sí ordena igual que el AMI en este caso, pero eso no lo convierte en un criterio confiable en general: mide ajuste de densidad, no correspondencia con una taxonomía.




Figura 6. AMI (externo) y silhouette (interno) a lo largo de las cuatro variantes de *covariance_type*. Los dos criterios señalan ganadores distintos.

IV-D1. Tres libertades, no una: Resulta tentador atribuir la ventaja de *full* a una única propiedad geométrica, pero la tabla no lo permite. Las cuatro variantes se distinguen por *tres* libertades independientes: si cada campana tiene matriz propia, si puede tener ancho distinto por eje, y si puede inclinarse respecto a los ejes del espacio. *tied* tiene inclinación pero no matriz propia por grupo (0.0750); *diag* tiene matriz propia y ancho por eje pero no inclinación (0.1441). Ninguna de las dos libertades por separado explica el salto: hace falta la combinación completa.

La geometría ajustada lo ilustra. En *diag* las tres campanas quedan con alargamientos de 2.0, 15.4 y 10.1, todas necesariamente a 0°; en *full* los alargamientos son 9.7, 16.7 y 2.6 con inclinaciones de 2,8°, 5,4° y 13,4°. Los anchos a lo largo de PC1 son similares entre las tres campanas de *full* (1.35, 1.22 y 1.02), mientras que a lo largo de PC2 difieren mucho más (0.26, 0.43 y 0.62).

Debe consignarse con honestidad el límite de este análisis: **el mecanismo fino no quedó aislado**. Los experimentos permiten mostrar *que* el salto ocurre y acotar *de qué libertades depende*, pero no derivar el *porqué* último a partir de las magnitudes medidas. Varias hipótesis intermedias que se formularon durante el análisis —que la ventaja provenía de explotar la correlación entre PC1 y PC3, o de estirar cada campana de forma distinta a lo largo de PC1— fueron contrastadas y descartadas por los propios datos.

IV-D2. Estabilidad: Ninguno de los resultados anteriores depende del azar de la inicialización. Sobre ocho semillas distintas, el AMI de la mezcla *full* sobre tres componentes tiene media 0.2434 y desviación estándar 0.0001 (rango 0.2432–0.2435), y el de K-medias sobre PC2+PC3 media 0.2092 con desviación 0.0002 (rango 0.2090–0.2093).

IV-E. Una representación alternativa: colores en vez de bandas

Dado que la física apunta al color y no al brillo, se probó construir el espacio directamente sobre las cuatro diferencias consecutivas $u-g$, $g-r$, $r-i$, $i-z$, en lugar de sobre las cinco magnitudes. El cambio altera la geometría por completo: la varianza deja de concentrarse (PC1 baja de 85.6 % a 47.3 %) y los centroides de K-medias pasan a repartirse 2.53 en PC1, 1.72 en PC2 y 0.77 en PC3, en vez de concentrarse en un solo eje.

Tabla IV
COMPARACIÓN DE REPRESENTACIONES Y MODELOS ($k = 3$, TRES COMPONENTES)

Representación	Modelo	Silhouette	AMI
PCA sobre bandas	K-medias	0.3800	0.0473
PCA sobre bandas	Mezcla gaussiana	0.3619	0.2434
PCA sobre colores	K-medias	0.3876	0.1775
PCA sobre colores	Mezcla gaussiana	0.2787	0.1243

El efecto sobre K-medias es notable: pasa de 0.0473 a 0.1775, casi cuatro veces mejor, simplemente por cambiar la representación de entrada sin tocar el algoritmo. **Preparar el espacio resultó más decisivo para K-medias que cualquier ajuste de sus hiperparámetros**. Sobre la mezcla gaussiana, en cambio, el mismo cambio es contraproducente ($0.2434 \rightarrow 0.1243$). Esto es coherente con lo observado en la Sección **IV-C**: su ventaja consistía en *neutralizar* el eje de brillo, no en extraer información de él. Removido ese eje de la representación, la flexibilidad extra de la covarianza completa deja de compensar y pasa a ser un costo, porque lo que ajusta es **densidad** y no separación de clases. La conclusión no es que una representación sea mejor, sino que **representación y modelo deben elegirse juntos**. La Figura 7 confirma además que los dos criterios siguen sin coincidir: la mejor combinación por silhouette (colores + K-medias, 0.3876) no es la mejor por AMI.

IV-F. Qué encontró realmente el mejor modelo

Un AMI de 0.2434 es un número abstracto; la tabla de contingencia dice qué significa. La Figura 8 la presenta en

sus dos lecturas complementarias, junto con la distribución de certeza del modelo. Leyendo por fila —a dónde fue a parar cada tipo real— el comportamiento es muy desigual entre las tres clases:

Tabla V
REPARTO DE CADA TIPO REAL ENTRE LOS TRES GRUPOS HALLADOS (POR FILA)

Tipo real	Grupo 0	Grupo 1	Grupo 2
GALAXY	0.059	0.319	0.623
QSO	0.840	0.016	0.144
STAR	0.284	0.423	0.293

Los cuásares son el éxito claro: el 84.0 % cae en un mismo grupo, que además está compuesto en un 62.4 % por cuásares. Tiene sentido físico, porque un cuásar tiene un espectro muy distintivo y por tanto un color muy característico. Las galaxias quedan mayoritariamente en un grupo (62.3 %) pero con una fuga importante. Las estrellas son el fracaso: se reparten casi uniformemente entre los tres grupos (0.284 / 0.423 / 0.293), es decir, **el modelo no las distingue en absoluto**.

El último hallazgo es el más instructivo desde el punto de vista metodológico. La mezcla asigna 85 429 de los 99 999 objetos (85.4 %) con una probabilidad máxima superior al 90 %, es decir, con muy poca duda. Restringido a esos objetos “seguros”, el AMI sube apenas de 0.2434 a 0.2890. **La certeza del modelo y su correspondencia con la realidad son dos cosas distintas**: el modelo está seguro y equivocado a la vez, porque la probabilidad que reporta mide el ajuste a las campanas que él mismo ajustó, no el acuerdo con la física.




Figura 7. Izquierda: AMI de las cuatro combinaciones de representación y modelo. Derecha: cada combinación situada sobre los dos criterios de evaluación a la vez.




Figura 8. Composición de los grupos hallados por la mezcla gaussiana *full*. Izquierda: de qué está hecho cada grupo. Centro: a dónde fue a parar cada tipo real. Derecha: distribución de la certeza de asignación.

V. CONCLUSIONES

1. **La varianza no es la utilidad.** El componente principal que concentra el 85.6 % de la varianza queda cuarto de cinco en información mutua con el tipo de objeto (0.068 nats), mientras que el segundo, con 11.8 % de varianza, es el más informativo (0.294). Elegir componentes por varianza acumulada —el único criterio disponible sin etiqueta— habría descartado señal útil y conservado ruido dominante.
2. **El supuesto geométrico del algoritmo determinó el resultado más que cualquier hiperparámetro.** K-medias, atado a la distancia euclidiana, partió los datos exclusivamente por brillo (separación de centroides: 4.76 en PC1 frente a 0.11 en PC2) y quedó en $AMI = 0,0473$. La mezcla gaussiana con covarianza *full*, que mide en distancia de Mahalanobis, alcanzó $AMI = 0,2434$ sobre los mismos datos.
3. **La ventaja de *full* depende de tres libertades combinadas**, no de una sola: matriz propia por grupo, ancho propio por eje e inclinación. El mecanismo fino no se logró aislar, y varias hipótesis intermedias fueron descartadas por los propios datos; se reporta el efecto medido, no una explicación que los experimentos no sostienen.
4. **Los criterios interno y externo no coinciden.** El mejor modelo por silhouette (*spherical*) es de los peores por AMI. Sin etiqueta solo se dispondría del silhouette, y este habría señalado el modelo equivocado. Es el límite estructural del aprendizaje no supervisado, no un defecto del experimento.
5. **Preparar la representación rindió más que ajustar el modelo, pero no de forma universal.** Cambiar de magnitudes a colores casi cuadruplicó el desempeño de K-medias ($0.0473 \rightarrow 0.1775$) y perjudicó a la mezcla gaussiana ($0.2434 \rightarrow 0.1243$). Representación y modelo deben elegirse juntos.
6. **Auditar la procedencia de las variables fue decisivo.** *redshift* habría resuelto el problema por sí solo, pero el tipo y el corrimiento se determinan de forma inseparable en el mismo ajuste; *plate*, *MJD* y *run_ID* superan a la mejor banda fotométrica, pero informan sobre el calendario del telescopio y no sobre el objeto.
7. **La certeza no es acierto.** El 85.4 % de los objetos se asignó con más del 90 % de probabilidad, y aun así el AMI restringido a ese subconjunto sube solo de 0.2434 a 0.2890. Un modelo probabilístico puede estar muy seguro y equivocado.
8. **Alcance real de lo logrado.** Desde la fotometría sola se recupera bien una clase (84.0 % de los cuásares en un mismo grupo), parcialmente otra (62.3 % de las galaxias) y nada de la tercera (las estrellas se reparten casi uniformemente). La conclusión práctica es que este enfoque podría servir para *priorizar* candidatos a cuásar para seguimiento espectroscópico, no para sustituir la clasificación espectroscópica.
9. **Reproducibilidad:** cuaderno completo en Google

Colab: <https://colab.research.google.com/drive/1vBsJbBqzO43cMjuuwcK8IQBVHYOaMvX?usp=sharing>.

APÉNDICE

A. Fragmentos de Código Clave

El cuaderno completo y ejecutable está en Google Colab (ver Conclusión 9); esta sección reproduce únicamente los fragmentos centrales para que el método sea legible sin salir del documento.

Auditoría por información mutua con línea base por permutación (Sección II-C):

```
mi = mutual_info_classif(
    limpio[candidatas], etiqueta_limpia,
    discrete_features=discretas,
    random_state=0)

generador = np.random.default_rng(0)
nulos = [
    mutual_info_classif(
        limpio[candidatas],
        pd.Series(generador.permutation(
            etiqueta_limpia.to_numpy())),
        discrete_features=discretas,
        random_state=0)
    for _ in range(3)]
mi_azar = np.mean(nulos, axis=0)
exceso = mi - mi_azar
```

PCA sobre las cinco bandas estandarizadas (Sección IV-A):

```
X = limpio[['u', 'g', 'r', 'i', 'z']].to_numpy()
X_esc = StandardScaler().fit_transform(X)

pca = PCA()
Z = pca.fit_transform(X_esc)

varianza = pca.explained_variance_ratio_
loadings = pca.components_.T
mi_componentes = mutual_info_classif(
    Z, etiqueta_limpia, random_state=0)
```

Comparación de covariance_type (Sección IV-D):

```
Z_red = Z[:, :3]
for forma in ['spherical', 'tied', 'diag', 'full']:
    gm = GaussianMixture(
        n_components=3, covariance_type=forma,
        random_state=0, n_init=3).fit(Z_red)
    pred = gm.predict(Z_red)
    bic = gm.bic(Z_red)
    sil = silhouette_score(
        Z_red[sub], pred[sub])
    ami = adjusted_mutual_info_score(
        etiqueta_limpia, pred)
```

Certeza de asignación del modelo final (Sección IV-F):

```
gmm_final = GaussianMixture(
    n_components=3, covariance_type='full',
    random_state=0, n_init=3).fit(Z_red)

grupos = gmm_final.predict(Z_red)
certeza = gmm_final.predict_proba(
```

```
Z_red).max(axis=1)
```

```
seguros = certeza > 0.9
ami_total = adjusted_mutual_info_score(
    etiqueta_limpia, grupos)
ami_seguros = adjusted_mutual_info_score(
    etiqueta_limpia[seguros], grupos[seguros])
```

REFERENCIAS

- [1] M. Fukugita, T. Ichikawa, J. E. Gunn, M. Doi, K. Shimasaku, and D. P. Schneider, "The Sloan Digital Sky Survey photometric system," *The Astronomical Journal*, vol. 111, pp. 1748–1756, 1996.
- [2] A. S. Bolton *et al.*, "Spectral classification and redshift measurement for the SDSS-III Baryon Oscillation Spectroscopic Survey," *The Astronomical Journal*, vol. 144, no. 5, p. 144, 2012.
- [3] N. R. Pogson, "Magnitudes of thirty-six of the minor planets for the first day of each month of the year 1857," *Monthly Notices of the Royal Astronomical Society*, vol. 17, no. 1, pp. 12–15, 1856.
- [4] H. Hotelling, "Analysis of a complex of statistical variables into principal components," *Journal of Educational Psychology*, vol. 24, pp. 417–441, 498–520, 1933, publicado en dos partes.
- [5] I. T. Jolliffe and J. Cadima, "Principal component analysis: A review and recent developments," *Philosophical Transactions of the Royal Society A*, vol. 374, no. 2065, p. 20150202, 2016.
- [6] J. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1. University of California Press, 1967, pp. 281–297.
- [7] S. P. Lloyd, "Least squares quantization in PCM," *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982.
- [8] A. P. Dempster, N. M. Laird, and D. B. Rubin, "Maximum likelihood from incomplete data via the EM algorithm," *Journal of the Royal Statistical Society, Series B*, vol. 39, no. 1, pp. 1–38, 1977.
- [9] G. J. McLachlan and D. Peel, *Finite Mixture Models*. New York, NY: John Wiley & Sons, 2000.
- [10] N. X. Vinh, J. Epps, and J. Bailey, "Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance," *Journal of Machine Learning Research*, vol. 11, pp. 2837–2854, 2010.
- [11] fedesoriano, "Stellar classification dataset — SDSS17," [Online]. Available: <https://www.kaggle.com/datasets/fedesoriano/stellar-classification-dataset-sdss17>, 2022, consultado el 5 de septiembre de 2026.
- [12] Abdurrouf *et al.*, "The seventeenth data release of the sloan digital sky surveys: Complete release of MaNGA, MaStar and APOGEE-2 data," *The Astrophysical Journal Supplement Series*, vol. 259, no. 2, p. 35, 2022.
- [13] SDSS Collaboration, "SDSS DR17 Schema Browser," [Online]. Available: <https://skyserver.sdss.org/dr17/MoreTools/browser>, 2022, glosario oficial de tablas y columnas del catálogo. Consultado el 5 de septiembre de 2026.
- [14] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed. Hoboken, NJ: Wiley-Interscience, 2006.
- [15] B. C. Ross, "Mutual information between discrete and continuous data sets," *PLoS ONE*, vol. 9, no. 2, p. e87357, 2014.
- [16] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [17] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, pp. 15:1–15:21, 2012.
- [18] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York, NY: Springer, 2009.
- [19] P. C. Mahalanobis, "On the generalised distance in statistics," *Proceedings of the National Institute of Sciences of India*, vol. 2, no. 1, pp. 49–55, 1936.
- [20] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.
- [21] G. Schwarz, "Estimating the dimension of a model," *The Annals of Statistics*, vol. 6, no. 2, pp. 461–464, 1978.
- [22] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY: Springer, 2006.