

Predicción de la Excentricidad Orbital de Exoplanetas mediante Aprendizaje Supervisado: Regresión Lineal vs. Random Forest

Jheison Martinez Bolivar
Maestría en Inteligencia Artificial
Universidad de La Salle, Bogotá, Colombia
jhmartinez07@unisalle.edu.co

Resumen—Este trabajo aplica dos modelos de aprendizaje supervisado —regresión lineal y Random Forest— para predecir la excentricidad orbital (`orbital_eccentricity`) de exoplanetas a partir del conjunto de datos NASA Exoplanet Archive Intelligence (6150 registros). Tras analizar la distribución de valores nulos en el Exploratorio de Datos (EDA), se justificó la excentricidad como variable objetivo dada su presencia de 15.25 % de datos faltantes y su alto valor astrofísico. Con un preprocesamiento de limpieza y escalado estandarizado (`StandardScaler`), se partitionaron los datos (80 % entrenamiento, 20 % prueba). La regresión lineal obtuvo $R^2 = 0,2721$ ($RMSE = 0,1158$, $MAE = 0,0681$), mientras que Random Forest ($n_estimators = 100$) alcanzó $R^2 = 0,3850$ ($RMSE = 0,1065$, $MAE = 0,0578$). Los resultados demuestran que las relaciones dinámicas entre las propiedades planetarias y estelares son esencialmente no lineales y que los métodos de ensamble capturan de manera superior estas interacciones complejas. El cuaderno con la implementación completa se encuentra disponible en Google Colab: <https://colab.research.google.com/drive/1UB8g-jYuwyeEerVtnyryVKVM9uYLOb07?usp=sharing>.

I. INTRODUCCIÓN

El descubrimiento y caracterización de exoplanetas —cuerpos celestes que orbitan estrellas distintas al Sol— representa uno de los campos de mayor impacto en la astrofísica contemporánea. Desde las primeras confirmaciones en la década de 1990 [1], catálogos oficiales como el *NASA Exoplanet Archive* centralizan miles de observaciones con decenas de parámetros físicos y orbitales [2].

La excentricidad orbital (e) describe la desviación de una órbita respecto a un círculo perfecto ($e = 0$). Estimar este parámetro es crucial para comprender la estabilidad orbital, los mecanismos de migración planetaria y la habitabilidad de un sistema. El uso de técnicas de aprendizaje automático en conjuntos de datos astronómicos con datos faltantes ha sido explorado recientemente para estimar propiedades planetarias inobservables [3]. Sin embargo, determinar e experimentalmente requiere observaciones prolongadas de velocidad radial o fotometría de tránsito de alta precisión, por lo que suele ser un dato faltante en los catálogos astronómicos.

En este estudio, desarrollado en el marco de la Maestría en Inteligencia Artificial de la Universidad de La Salle, se utiliza el conjunto de datos *NASA Exoplanet Archive Intelligence* [4] para formular un problema predictivo real: estimar la excentricidad orbital a partir de variables físicas de la estrella

y del planeta. Se comparan dos enfoques: un modelo baseline de **Regresión Lineal** [5] y un modelo no lineal de ensamble **Random Forest** [6], [7], [8]. El cuaderno interactivo con el experimento completo está publicado en [Google Colab](#).

II. EXPLORACIÓN DE DATOS Y PREPROCESAMIENTO

II-A. Análisis Exploratorio de Datos (EDA) y Selección del Target

El dataset original contiene 6150 observaciones. Como primer paso del EDA, se analizó el porcentaje de valores nulos para fundamentar de forma empírica la elección del *target* (Figura 1).




Figura 1. Porcentaje de valores nulos por variable en el conjunto de datos.

Variables como `equilibrium_temp_k` (25.4 %) y `star_age_gyr` (21.3 %) fueron descartadas como predictores por su excesiva falta de datos. En cambio, `orbital_eccentricity` presenta un 15.25 % de nulos, convirtiéndola en una variable objetivo idónea para imputación predictiva.

La distribución del target (Figura 2) evidencia una marcada asimetría positiva, con el 75 % de los valores por debajo de $e = 0,25$, reflejando la predominancia de órbitas casi circulares en los descubrimientos actuales.




Figura 2. Histograma y boxplot de la variable objetivo `orbital_eccentricity`.

II-B. Análisis de Correlación

Se evaluó la correlación de Pearson entre las 13 variables seleccionadas y la excentricidad (Figura 3). Las correlaciones más elevadas corresponden a la magnitud visual estelar `star_vmag` ($r = -0,46$), la masa planetaria `planet_mass_earth` ($r = +0,41$) y el radio planetario `planet_radius_earth` ($r = +0,39$).




Figura 3. Correlación de Pearson de cada variable predictora con `orbital_eccentricity`.

Dado que ningún predictor individual supera un $|r| > 0,5$, se concluye que no existe una relación lineal fuerte directa, lo que fundamenta la necesidad de probar algoritmos no lineales de aprendizaje supervisado.

II-C. Preprocesamiento

Tras eliminar las filas con nulos en las variables de interés, se obtuvieron 4924 registros limpios. La partición de datos se realizó en una proporción 80 % para entrenamiento (3939 muestras) y 20 % para prueba (985 muestras) con `random_state=42`.

Para la Regresión Lineal, se aplicó estandarización con `StandardScaler` ($z = \frac{x-\mu}{\sigma}$) sobre los predictores para corregir las diferencias de escala entre magnitudes como el período orbital (días) y la masa.

III. METODOLOGÍA DE MODELADO

III-A. Regresión Lineal (Baseline)

Modela el target como $\hat{y} = \beta_0 + \sum_{i=1}^p \beta_i x_i$, estimando los coeficientes mediante Mínimos Cuadrados Ordinarios (OLS) sobre las variables estandarizadas [5].

III-B. Random Forest

Consiste en un ensamble de 100 árboles de decisión ($n_{estimators} = 100$, $min_samples_{leaf} = 2$) entrenados mediante muestreo bootstrap [6], [8]. La predicción final corresponde al promedio de las salidas individuales.

La evaluación de ambos modelos combinó métricas sobre el conjunto de prueba reservado (R^2 , $RMSE$, MAE) y validación cruzada de 5 pliegues (k -fold CV) [9].

IV. RESULTADOS Y DISCUSIÓN

La Tabla I y la Figura 4 resumen el desempeño comparativo de ambos modelos.

Cuadro I
MÉTRICAS COMPARATIVAS EN CONJUNTO DE PRUEBA Y VALIDACIÓN CRUZADA

Métrica	Regresión Lineal	Random Forest
R^2 (Test)	0.2721	0.3850
RMSE (Test)	0.1158	0.1065
MAE (Test)	0.0681	0.0578
R^2 CV-5fold	$0,3166 \pm 0,0415$	$0,4180 \pm 0,0291$




Figura 4. Comparación de métricas R^2 , $RMSE$ y MAE entre modelos.

El modelo **Random Forest** superó a la Regresión Lineal en todas las métricas, alcanzando un $R^2 = 0,3850$ en test y $0,4180$ en validación cruzada. El análisis de importancia de variables y residuos para Random Forest se presenta en la Figura 5.




Figura 5. Importancia de variables (Gini) y distribución de residuos para Random Forest.

V. CONCLUSIONES

1. **Random Forest supera a la Regresión Lineal:** El incremento en R^2 de 0.2721 a 0.3850 confirma la existencia de patrones no lineales en la excentricidad orbital.
2. **Predictores dominantes:** La masa del planeta, el radio planetario y la magnitud estelar son las variables de mayor peso predictivo.
3. **Aplicabilidad y Reproducibilidad:** El modelo de ensamble desarrollado en el marco académico de la Universidad de La Salle permite estimar la excentricidad en los exoplanetas con datos faltantes. El experimento completo es totalmente reproducible a través del cuaderno publicado en Google Colab: <https://colab.research.google.com/drive/1UB8g-jYuwyeEerVtnyryVKVM9uYLOb07?usp=sharing>.

REFERENCIAS

- [1] A. Wolszczan and D. A. Frail, "A planetary system around the millisecond pulsar PSR1257+12," *Nature*, vol. 355, pp. 145–147, 1992.
- [2] NASA Exoplanet Science Institute, "NASA Exoplanet Archive," <https://exoplanetarchive.ipac.caltech.edu/>, 2026.
- [3] F. Lalande, E. Tasker, and K. Doya, "Estimating exoplanet mass using machine learning on incomplete datasets," *The Open Journal of Astrophysics*, vol. 7, Oct 2024. [Online]. Available: <https://arxiv.org/abs/2410.06922>
- [4] K. Kanchana, "NASA exoplanet archive intelligence," <https://www.kaggle.com/datasets/kanchana1990/nasa-exoplanet-archive-intelligence>, 2024.
- [5] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York, NY: Springer, 2009.
- [6] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [7] E. Kavlakoglu, "Random forest," <https://www.ibm.com/mx-es/think/topics/random-forest>, Mar 2026. [Online]. Available: <https://www.ibm.com/mx-es/think/topics/random-forest>
- [8] J. Amat Rodrigo, "Random forest con python," https://cienciadedatos.net/documentos/py08_random_forest_python, 2026. [Online]. Available: https://cienciadedatos.net/documentos/py08_random_forest_python
- [9] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.