

Series Temporales: ¿La Actividad Solar Ayuda a Predecir la Temperatura Global?

ARIMA, LSTM y DQN sobre Manchas SILSO y Anomalías Berkeley Earth

Jheison Martinez Bolivar
Maestría en Inteligencia Artificial
Universidad de La Salle, Bogotá, Colombia
 jhmartinez07@unisalle.edu.co

Resumen—Este trabajo pregunta si la actividad solar aporta señal predictiva a la temperatura global mensual. Sobre el marco común 1880–2025 (1751 meses, sin nulos ni duplicados) se compara la anomalía terrestre `land` de Berkeley Earth contra el conteo de manchas SILSO como variable exógena, con corte temporal en 2001 (entrenamiento $n = 1452$, prueba $n = 299$). El ARIMA(2,1,1) elegido por AIC obtiene $RMSE = 0,4637$ en la prueba; añadir el sol lo empeora ($RMSE = 0,5121$, $\beta = -6,07 \times 10^{-6}$ con $p = 0,96$). La LSTM univariada empató al ARIMA ($RMSE = 0,4799$) y la multivariada pierde en las tres semillas ($RMSE$ entre 0.50 y 1.05), así que la hipótesis solar queda enterrada por las dos vías. La misma tabla incluye la línea base que ningún modelo supera: la persistencia marca $RMSE = 0,1216$, casi cuatro veces mejor que el ARIMA, de modo que el objeto del trabajo no es predecir la temperatura sino medir lo que cuesta añadir el sol. En bloque aparte, un DQN con acciones discretizadas aprende a estabilizar el péndulo de `Pendulum-v1` (retorno voraz -200 ± 38 entre tres semillas contra -1170 ± 238 del azar). El cuaderno con la implementación completa se ejecuta en Colab desde https://colab.research.google.com/github/JheisonMB/ml/blob/main/series-temporales-prediccion/series_temporales_prediccion.ipynb.

I. INTRODUCCIÓN

EL Sol impone un ciclo de unos once años sobre su propia actividad, visible en el conteo de manchas [1], y el clima terrestre guarda memoria de largo plazo en sus anomalías de temperatura [2], [3]. La pregunta de si el primero ayuda a predecir la segunda es anterior al aprendizaje automático y sigue abierta en su forma predictiva: no si el Sol causa el clima, sino si ver las manchas reduce el error de pronóstico de la temperatura.

Este trabajo la convierte en una comparación cerrada: la misma serie, el mismo corte temporal, los mismos errores, con y sin la variable solar. Del lado estadístico, ARIMA y su extensión con exógena ARIMAX [4]; del lado aprendido, redes LSTM univariadas y multivariadas [5], [6]. En bloque independiente, y porque la actividad también lo pide, un agente DQN [7] sobre un entorno de control continuo. La metodología de series sigue la referencia canónica de pronóstico [8].

II. DATOS Y PREPROCESAMIENTO

II-A. Selección de los Conjuntos de Datos

Se usan dos fuentes con cobertura mensual solapada desde 1880. Las manchas provienen del conteo mensual total SILSO v2.0 [2]: el observatorio lo distribuye en texto de ancho fijo y son siete columnas [2], y el archivo que se usa aquí, `SN_m_tot_V2.0.csv` sin encabezado y con separador `;`, es la copia tabular de la plataforma de cursos [9]. La temperatura proviene de las anomalías mensuales Berkeley Earth (columnas `time`, `station`, `land`), donde cada valor es la desviación del mes respecto a su referencia climática de 1951–1980 [3], [10], [11]. Una anomalía no es la temperatura del termómetro: $+0,5$ significa medio grado por encima de lo normal para ese mes.

Como protagonista se fija `land` (solo tierra): trae menos dispersión que la combinada `station` ($\sigma = 0,41$ contra $0,52$) y es la serie limpia del conjunto; su correlación mensual contemporánea con las manchas es prácticamente cero en ambas ($\approx 0,02$), así que un vínculo instantáneo queda descartado desde el EDA.

II-B. Marco Común y Limpieza

El tiempo decimal de Berkeley Earth se convierte a mes calendario por truncamiento, no por redondeo: redondear salta febrero y duplica abril, defecto que se detectó por 585 fechas duplicadas y se corrigió antes de seguir. El marco común 1880–01 a 2025–11 queda con $n = 1751$ meses contiguos, cero nulos y cero duplicados. La Figura 1 muestra las dos series en nivel.

La descomposición aditiva de `land` con período 12 (Figura 2) muestra una tendencia que recorre más de un grado y un componente anual mínimo ($\pm 0,03^\circ\text{C}$). Esa cifra hay que leerla con cuidado: `land` es un promedio global de tierra, y al descontar cada mes contra su climatología el ciclo estacional ya está parcialmente compensado entre hemisferios. Lo que sobrevive no es una estación meteorológica sino el residuo de esa compensación, que depende de cuánta tierra hay en cada hemisferio y no de un mecanismo climático; por eso la lectura (marzo $+0,025^\circ\text{C}$, octubre $+0,023^\circ\text{C}$, junio $-0,028^\circ\text{C}$, con mediana en los mismos tres meses) no encaja con el verano del




Figura 1. Anomalia terrestre land (arriba) y manchas solares mensuales (abajo), 1880–2025.

hemisferio norte y no debe interpretarse como señal climática. La dispersión por década, en cambio, sí crece en las décadas recientes, y solo se ve midiéndola sobre el residuo al que se le quitan la tendencia y el componente estacional, no sobre la serie cruda donde la pendiente la disfraza.

El ciclo solar de unos once años es un rasgo mostrado de la serie [1] y se caracteriza pico a pico sobre la suavizada de 13 meses que usa el SILSO, exigiendo casi una década entre máximos porque cada ciclo trae picos dobles: 14 máximos con un intervalo medio cercano a los 130 meses. Ese intervalo es una medida de distancia entre picos, no un análisis espectral: el cuaderno no calcula periodograma ni densidad espectral, así que la correspondencia con los 11 años canónicos viene del conteo de máximos y no de una transformada. La Figura 3 los marca.

El corte es estrictamente temporal: entreno 1880–2000 ($n = 1452$) y prueba 2001 en adelante ($n = 299$), sin barajar. La validación de la LSTM sale de dentro del entreno (1991–2000), sin tocar la prueba.

III. METODOLOGÍA

III-A. ARIMA y ARIMAX

El test ADF [12] sobre el entreno no rechaza raíz unitaria en nivel ($p = 0,42$) y sí en primera diferencia ($p \approx 0$), de modo que $d = 1$. La ACF de la diferencia corta en el rezago uno y la PACF decae gradualmente, firma de media móvil de orden uno; el AIC sobre el entreno elige ARIMA(2,1,1) frente a sus vecinos. El modelo pronostica como

$$\Delta y_t = \phi_1 \Delta y_{t-1} + \phi_2 \Delta y_{t-2} + \theta_1 \varepsilon_{t-1} + \varepsilon_t, \quad (1)$$

sin término constante: con $d = 1$ la diferenciación ya se lleva el nivel, y el modelo ajustado por el AIC no incluye ninguno. El ARIMAX añade la mancha como regresor exógeno con el mismo orden y el mismo corte, de modo que P2 compara con

sol contra sin sol; como $d = 1$, la relación se estima sobre la serie diferenciada, y lo que se pone a prueba es si el aumento de la mancha en un mes acompaña el aumento de la anomalía en ese mismo mes. Lo que aporta el sol es medible y es nulo: $\beta = -6,07 \times 10^{-6}$ con $p = 0,96$ sobre el entreno, y el error en la prueba sube. P2 es una confirmación de lo que la correlación contemporánea del EDA ya había anunciado, no un hallazgo que la pondere contradiga.

III-B. LSTM Univariada y Multivariada

La celda LSTM [5] decide qué olvidar, qué guardar y qué mostrar mediante sus compuertas:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t, \quad (2)$$

donde f_t e i_t son las compuertas de olvido y entrada. La red (LSTM de 32 unidades más capa densa) ve ventanas de 24 meses y pronostica la prueba de forma recursiva sin mirar sus datos; la versión multivariada recibe además las manchas futuras observadas, como exógena que es [6]. Misma arquitectura, misma semilla, mismas ventanas: P3 es el *ablation* que P2 dejó pendiente, y se repite con tres semillas porque el número exacto baila entre corridas aun con igual semilla (no-determinismo de GPU).

III-C. DQN sobre el Péndulo

En Pendulum-v1 [13], sobre la interfaz estándar de GYMNASIUM [14], el torque continuo se discretiza en cinco empujones y la red Q minimiza

$$L = \mathbb{E} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right], \quad (3)$$

con caja de recuerdos, red objetivo congelada y ε decreciente durante 300 episodios. El listón es el agente al azar (-170 ± 238 de retorno medio en 20 episodios, con el entorno sembrado).




Figura 2. Descomposición aditiva de `land` con período 12. Arriba, la serie observada; en el centro, la tendencia por promedio móvil centrado de 12 meses; abajo, el perfil estacional del residuo, que son los doce meses del período y no los 146 años superpuestos. La banda sombreada es el rango intercuartílico de cada mes a lo largo del período: es tres veces más ancho que la línea de media, que es la forma de ver que la estacionalidad es mucho menor que la variación entre años.

IV. RESULTADOS Y DISCUSIÓN

La Tabla I resume la prueba y la Figura 4 la dibuja. Antes de leerla hay que decirlo: la fila que gana no es un modelo, es copiar el mes anterior. La persistencia saca 0,1216, y el ARIMA que sin ellas parecería el mejor se queda en 0,4637, casi cuatro veces peor. La temperatura mensual es una serie suave y el error de un paso del ARIMA se realimenta a lo largo de 299 pasos de prueba. El drift lineal, que solo arrastra la pendiente histórica sin realimentar nada, tampoco ayuda: se queda en 0,5168, incluso por detrás del ARIMA, porque extender el calentamiento en línea recta lo desvía un poco más cada año. Así que el margen de este trabajo no es predecir la temperatura, y el informe no lo reclama.

Dentro de esa tabla, lo que sí se sostiene es la pregunta del trabajo. P1: el ARIMA se predice con el propio pasado pero su pronóstico de horizonte largo se queda plano y no acompaña la subida. P2: el sol no aporta señal, con $\beta = -6,07 \times 10^{-6}$, error estándar $1,13 \times 10^{-4}$ y $p = 0,96$ sobre el entreno, y error mayor en la prueba (RMSE = 0,5121). P3: la LSTM sin sol empata al ARIMA y con sol pierde en las tres semillas. Que la red con más información pierda es el hallazgo que rompe la intuición del trabajo, aunque parte de ese derrumbe sea la inestabilidad del rollout recursivo a ese horizonte y no el canal solar en sí.

Todos los modelos quedan por debajo de una regla sin

Cuadro I

ERROR SOBRE LA PRUEBA 2001 EN ADELANTE ($n = 299$). LAS DOS PRIMERAS FILAS NO SON MODELOS: SON LAS REGLAS SIN PARÁMETROS A LAS QUE TODO LO DEMÁS DEBERÍA GANARLE.

Modelo	RMSE	MAE
Persistencia $\hat{y}_t = y_{t-1}$	0.1216	0.0974
Drift lineal	0.5168	0.4687
ARIMA(2,1,1)	0.4637	0.3998
ARIMAX(2,1,1) con sol	0.5121	0.4537
LSTM sin sol	0.4799	0.4181
LSTM con sol	0.9709	0.8770

parámetros, y aun así el sol nunca ayuda: por donde se mire, añadir las manchas cuesta error. Esa es la conclusión del trabajo, y es un resultado negativo bien circunscrito, no una hipótesis sin probar.

El bloque RL sí aprende: de nivel azar a retorno voraz -183 ± 108 en la semilla principal y -243 ± 306 y -174 ± 108 en las dos de robustez, con la curva de la Figura 5. La evaluación empareja los ángulos iniciales del agente con los del azar, de modo que la comparación no es solo estadística.

V. CONCLUSIONES

1. La temperatura mensual no necesita un modelo: copiar el mes anterior la pronostica a 0,1216 de RMSE, casi




Figura 3. Manchas solares con los 14 máximos del ciclo sobre la serie suavizada.




Figura 4. Observada contra los cuatro pronósticos sobre la prueba: persistencia, drift, ARIMA y ARIMAX con sol. La línea que se ajusta a la observada es la de persistencia.




Figura 5. Retorno por episodio del DQN, media móvil de 20.

cuatro veces mejor que el ARIMA ajustado por AIC. Ninguno de los tres modelos aprendidos queda por encima de esa regla sin parámetros a 25 años de horizonte, y la otra regla sin parámetros, el drift lineal, tampoco la alcanza (0,5168, peor que el propio ARIMA), así que este trabajo no demuestra que la serie sea difícil de anticipar: demuestra que su historia lineal no es el problema.

2. La actividad solar, con su ciclo decenal bien medido, no aporta señal predictiva mensual a la temperatura en este marco. El EDA ya lo había adelantado con la correlación contemporánea nula; P2 y P3 lo confirman en el modelo, con $\beta = -6,07 \times 10^{-6}$ y $p = 0,96$ y con la red

multivariada peor. Es una confirmación declarada, no un hallazgo nuevo.

3. El aprendizaje por refuerzo sí resuelve su tarea continua cuando la recompensa guía paso a paso: el agente voraz llega a -200 ± 38 de retorno medio entre las tres semillas frente a -1170 ± 238 del azar, y la dispersión entre semillas es menor que la dispersión dentro de cada una, así que la mejora es consistente y no un tirador afortunado. Lo que no se puede afirmar con tres semillas y cinco acciones discretas es que esto ocurra *desde cualquier semilla*.
4. Reproducibilidad: cuaderno ejecutado de punta a punta, con `requirements.txt` pinneado en local, las tres semillas fijadas en el entorno de GYMNASIUM además de en `torch` y `numpy`, y las figuras exportadas por `export_figures.py` a `assets/images/`. En Colab el cuaderno corre sin pines para no romper la imagen preinstalada, así que ahí las cifras pueden variar en el orden del cuarto decimal; los valores citados salen de la corrida con `requirements.txt`. El cuaderno completo se ejecuta en Colab desde https://colab.research.google.com/github/JheisonMB/ml/blob/main/series-temporales-prediccion/series_temporales_prediccion.ipynb.

APÉNDICE

Fragmentos de Código Clave

Cada fragmento es el pasaje del cuaderno que sostiene una afirmación concreta del texto. Se reproducen tal cual, sin reescribir, para que las conclusiones se puedan verificar sin ejecutar el cuaderno.

A. La fecha decimal se trunca, no se redondea. La columna `time` de Berkeley Earth viene como año decimal. Redondearla salta febrero por completo, duplica abril y deja 585 fechas repetidas; el cálculo entero de año y mes es lo que deja el marco en 1751 meses *unicos*, que es la base sobre la que están calculadas la Tabla I y la Figura 4.

```
tmp_year = tmp['time'].astype(int)
tmp_month = ((tmp['time'] - tmp_year) * 12).
    astype(int) + 1
tmp_month = tmp_month.clip(1, 12)
tmp['date'] = pd.to_datetime(dict(year=
    tmp_year, month=tmp_month, day=1))
tmp = tmp.set_index('date').sort_index()
```

B. El escalador se ajusta sin ver la prueba. El `StandardScaler` se ajusta solo hasta 1990-12, dentro del bloque de ajuste; la transformación después se aplica a toda la serie, pero la media y la desviación vienen del pasado. Por eso el bloque de ventanas de la LSTM no filtra información de 2001 en adelante.

```
fit_end = '1990-12-01'
fit_frame = frame.loc[:fit_end]
scalers = {col: StandardScaler().fit(
    fit_frame[[col]])
    for col in ['land', 'sunspots']}
fit_mask = dates <= fit_end
val_mask = (dates > fit_end) & (dates <= '
    2000-12-01')
```

C. El pronóstico es recursivo y arranca en el borde del entreno. No hay teacher forcing: cada paso del 2001 al 2025 se alimenta de la predicción anterior, no del valor observado. Los 299 pasos de realimentación son la razón de que la LSTM multivariada termine colapsando y la razón también de que el ARIMA pierda frente a la persistencia: el error de un paso se acumula durante todo el horizonte.

```
history = list(data[len(fit_frame) - window:
    len(train)])
upcoming_sun = scaled.loc[test.index, '
    sunspots'].values
with torch.no_grad():
    for step in range(len(test)):
        features = torch.Tensor(np.array(
            history[-window:] [None])).to(device)
        guess = float(net(features))
        if len(columns) == 1:
            history.append([guess])
        else:
            history.append([guess, upcoming_sun[
                step]])
```

D. Las dos líneas base. Es el fragmento que decide el marco del trabajo: sin estas dos reglas, la comparación de la Tabla I se hace entre modelos y no dice nada sobre si alguno de ellos es mejor que no hacer nada.

```
persistence = frame['land'].shift(1).loc[test
    .index]
slope = (train['land'].iloc[-1] - train['land'
    ''].iloc[0]) / (len(train) - 1)
drift = pd.Series(train['land'].iloc[-1] +
    slope * np.arange(1, len(test) + 1),
    index=test.index)
```

E. La evidencia del resultado central. El p-valor del coeficiente solar se calcula sobre el bloque de ajuste y se imprime antes de mirar la métrica de la prueba, que es el orden honesto: si se mira el RMSE primero, la interpretación ya viene sesgada.

```
coef = exog_fit.params['sunspots']
err = exog_fit.bse['sunspots']
pval = exog_fit.pvalues['sunspots']
```

F. El entorno de GYMNASIUM también va sembrado. `torch.manual_seed` y `numpy.seed` no controlan el estado inicial de un entorno: `gym.make` no acepta seed, que hay que pasar a `reset`. Sin esto, el agente al azar y el agente voraz no comparten los ángulos de partida y la comparación de la Figura 5 no es pareada.

```
eval_env = gym.make('Pendulum-v1')
for episode in range(20):
    observation, _ = eval_env.reset(seed=
        EVAL_SEED + episode)
```

G. Exportación de las figuras. Las cinco figuras del informe salen de este script, no del cuaderno: el cuaderno calcula y muestra, el script escribe en `assets/images/`.

```
./venv/bin/python export_figures.py
```

REFERENCIAS

- [1] D. H. Hathaway, "The Solar Cycle," *Living Reviews in Solar Physics*, vol. 12, p. 4, 2015.
- [2] WDC-SILSO, Royal Observatory of Belgium, "SILSO sunspot number data files, monthly mean total sunspot number," [Online]. Available: <https://www.sidc.be/silso/>, 2025.
- [3] Berkeley Earth, "Global land temperature anomalies, monthly land average," [Online]. Available: <https://berkeleyearth.org/data/>, 2024.
- [4] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed. Hoboken, NJ: Wiley, 2015.
- [5] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [6] B. Lim, S. Ö. Arık, N. Loeff, and T. Pfister, "Temporal fusion transformers for interpretable multi-horizon time series forecasting," *International Journal of Forecasting*, vol. 37, no. 4, pp. 1748–1764, 2021.
- [7] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, and D. Hassabis, "Human-level control through deep reinforcement learning," *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.
- [8] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne, Australia: OTexts, 2021, available: <https://otexts.com/fpp3/>.
- [9] gallo33henrique, "Sunspot numbers dataset 1700–2025," [Online]. Available: <https://www.kaggle.com/datasets/gallo33henrique/sunspot-numbers-dataset-17002025>, 2025.
- [10] R. A. Rohde and Z. Hausfather, "The Berkeley Earth Land/Ocean Temperature Record," *Earth System Science Data*, vol. 12, no. 4, pp. 3469–3479, 2020.

- [11] adarshsalukhe, “Global land temperature anomalies 1880–2024,” [Online]. Available: <https://www.kaggle.com/datasets/adarshsalukhe/global-land-temperature-anomalies-1880-2024>, 2024.
- [12] D. A. Dickey and W. A. Fuller, “Distribution of the estimators for autoregressive time series with a unit root,” *Journal of the American Statistical Association*, vol. 74, no. 366, pp. 427–431, 1979.
- [13] Farama Foundation, “Pendulum: Continuous control environment,” [Online]. Available: https://gymnasium.farama.org/environments/classic_control/pendulum/, 2024.
- [14] M. Towers, A. Kwiatkowski, J. Terry, J. U. Balis, G. De Cola, T. Deleu, M. Goulão, A. Kallinteris, M. Krimmel, A. KG, R. Perez-Vicente, A. Pierré, S. Schulhoff, J. J. Tai, H. Tan, and O. G. Younis, “Gymnasium: A standard interface for reinforcement learning environments,” *arXiv preprint arXiv:2407.17032*, 2024.