

Series Temporales: ¿La Actividad Solar Ayuda a Predecir la Temperatura Global?

ARIMA, LSTM y DQN sobre Manchas SILSO y Anomalías Berkeley Earth

Jheison Martinez Bolivar
Maestría en Inteligencia Artificial
Universidad de La Salle, Bogotá, Colombia
 jhmartinez07@unisalle.edu.co

Resumen—Este trabajo pregunta si la actividad solar aporta señal predictiva a la temperatura global mensual. Sobre el marco común 1880–2025 (1751 meses, sin nulos ni duplicados) se compara la anomalía terrestre `land` de Berkeley Earth contra el conteo de manchas SILSO como variable exógena, con corte temporal en 2001 (entrenamiento $n = 1452$, prueba $n = 299$). El ARIMA(2,1,1) elegido por AIC obtiene $RMSE = 0,4637$ en la prueba; añadir el sol lo empeora ($RMSE = 0,5121$, coeficiente prácticamente cero). La LSTM univariada empata al ARIMA ($RMSE = 0,4799$) y la multivariada pierde en las tres semillas ($RMSE$ entre 0.50 y 1.05), así que la hipótesis solar queda enterrada por las dos vías. En bloque aparte, un DQN con acciones discretizadas aprende a estabilizar el péndulo de `Pendulum-v1` (retorno voraz ≈ -199 contra ≈ -1117 del azar, estable en tres semillas). El cuaderno con la implementación completa se ejecuta en Colab desde https://colab.research.google.com/github/JheisonMB/ml/blob/main/series-temporales-prediccion/series_temporales_prediccion.ipynb.

v2.0 [2]: el observatorio lo distribuye en texto de ancho fijo y son siete columnas [2], y el archivo que se usa aquí, `SN_m_tot_V2.0.csv` sin encabezado y con separador `;`, es la copia tabular de la plataforma de cursos [9]. La temperatura proviene de las anomalías mensuales Berkeley Earth (columnas `time`, `station`, `land`), donde cada valor es la desviación del mes respecto a su referencia climática de 1951–1980 [3], [10], [11]. Una anomalía no es la temperatura del termómetro: $+0,5$ significa medio grado por encima de lo normal para ese mes.

Como protagonista se fija `land` (solo tierra): trae menos dispersión que la combinada `station` ($\sigma = 0,41$ contra $0,52$) y es la serie limpia del conjunto; su correlación mensual contemporánea con las manchas es prácticamente cero en ambas ($\approx 0,02$), así que un vínculo instantáneo queda descartado desde el EDA.

I. INTRODUCCIÓN

EL Sol impone un ciclo de unos once años sobre su propia actividad, visible en el conteo de manchas [1], y el clima terrestre guarda memoria de largo plazo en sus anomalías de temperatura [2], [3]. La pregunta de si el primero ayuda a predecir la segunda es anterior al aprendizaje automático y sigue abierta en su forma predictiva: no si el Sol causa el clima, sino si ver las manchas reduce el error de pronóstico de la temperatura.

Este trabajo la convierte en una comparación cerrada: la misma serie, el mismo corte temporal, los mismos errores, con y sin la variable solar. Del lado estadístico, ARIMA y su extensión con exógena ARIMAX [4]; del lado aprendido, redes LSTM univariadas y multivariadas [5], [6]. En bloque independiente, y porque la actividad también lo pide, un agente DQN [7] sobre un entorno de control continuo. La metodología de series sigue la referencia canónica de pronóstico [8].

II. DATOS Y PREPROCESAMIENTO

II-A. Selección de los Conjuntos de Datos

Se usan dos fuentes con cobertura mensual solapada desde 1880. Las manchas provienen del conteo mensual total SILSO

II-B. Marco Común y Limpieza

El tiempo decimal de Berkeley Earth se convierte a mes calendario por truncamiento, no por redondeo: redondear salta febrero y duplica abril, defecto que se detectó por 585 fechas duplicadas y se corrigió antes de seguir. El marco común 1880–01 a 2025–11 queda con $n = 1751$ meses contiguos, cero nulos y cero duplicados. La Figura 1 muestra las dos series en nivel.

La descomposición aditiva de `land` con período 12 (Figura 2) muestra una tendencia que recorre más de un grado y un componente anual mínimo ($\pm 0,03^\circ\text{C}$): la anomalía descuenta las estaciones al medirse contra su propio mes, y la lectura estacional que sobrevive (marzos y octubres altos, junios bajos) no corresponde a estaciones de ningún hemisferio. La dispersión por década crece en las décadas recientes.

El ciclo solar de unos once años es un rasgo mostrado de la serie [1] y se caracteriza pico a pico sobre la suavizada de 13 meses que usa el SILSO, exigiendo casi una década entre máximos porque cada ciclo trae picos dobles: 14 máximos con intervalos alrededor de la decena de años (pico espectral en ≈ 125 meses). La Figura 3 los marca.

El corte es estrictamente temporal: entrenamiento 1880–2000 ($n = 1452$) y prueba 2001 en adelante ($n = 299$), sin barajar.




Figura 1. Anomalía terrestre land (arriba) y manchas solares mensuales (abajo), 1880–2025.




Figura 2. Tendencia por promedio móvil centrado de 12 meses y perfil estacional de 12 meses de land.

La validación de la LSTM sale de dentro del entreno (1991–2000), sin tocar la prueba.

III. METODOLOGÍA

III-A. ARIMA y ARIMAX

El test ADF [12] sobre el entreno no rechaza raíz unitaria en nivel ($p = 0,42$) y sí en primera diferencia ($p \approx 0$), de modo que $d = 1$. La ACF de la diferencia corta en el rezago uno y la PACF decae gradualmente, firma de media móvil de

orden uno; el AIC sobre el entreno elige ARIMA(2,1,1) frente a sus vecinos. El modelo pronostica como

$$\Delta y_t = \phi_1 \Delta y_{t-1} + \phi_2 \Delta y_{t-2} + \theta_1 \varepsilon_{t-1} + \varepsilon_t, \quad (1)$$

sin término constante: con $d = 1$ la diferenciación ya se lleva el nivel, y el modelo ajustado por el AIC no incluye ninguno. El ARIMAX añade la mancha como regresor exógeno con el mismo orden y el mismo corte, de modo que P2 compara con sol contra sin sol; como $d = 1$, la relación se estima sobre la serie diferenciada, y lo que se pone a prueba es si el aumento de la mancha en un mes acompaña el aumento de la anomalía en ese mismo mes. Lo que aporta el sol es medible y es nulo:




Figura 3. Manchas solares con los 14 máximos del ciclo sobre la serie suavizada.

$\beta = -6,07 \times 10^{-6}$ con $p = 0,96$ sobre el entreno, y el error en la prueba sube. P2 es una confirmación de lo que la correlación contemporánea del EDA ya había anunciado, no un hallazgo que la pondere contradiga.

III-B. LSTM Univariada y Multivariada

La celda LSTM [5] decide qué olvidar, qué guardar y qué mostrar mediante sus compuertas:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t, \quad (2)$$

donde f_t e i_t son las compuertas de olvido y entrada. La red (LSTM de 32 unidades más capa densa) ve ventanas de 24 meses y pronostica la prueba de forma recursiva sin mirar sus datos; la versión multivariada recibe además las manchas futuras observadas, como exógena que es [6]. Misma arquitectura, misma semilla, mismas ventanas: P3 es el *ablation* que P2 dejó pendiente, y se repite con tres semillas porque el número exacto baila entre corridas aun con igual semilla (no-determinismo de GPU).

III-C. DQN sobre el Péndulo

En Pendulum-v1 [13], sobre la interfaz estándar de GYMNASIUM [14], el torque continuo se discretiza en cinco empujones y la red Q minimiza

$$L = \mathbb{E} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right], \quad (3)$$

con caja de recuerdos, red objetivo congelada y ε decreciente durante 300 episodios. El listón es el agente al azar (≈ -117 de retorno medio).

IV. RESULTADOS Y DISCUSIÓN

La Tabla I resume la prueba y la Figura 4 la dibuja. P1: el ARIMA se predice con el propio pasado pero su pronóstico de horizonte largo se queda plano y no acompaña la subida (RMSE = 0,4637). P2: el sol no aporta señal, con coeficiente prácticamente cero y error mayor (RMSE = 0,5121). P3: la LSTM sin sol empató al ARIMA (RMSE = 0,4799) y con sol pierde en las tres semillas (0,50–1,05): la hipótesis solar queda enterrada por las dos vías. Que la red con más

Cuadro I
ERROR SOBRE LA PRUEBA 2001 EN ADELANTE ($n = 299$).

Modelo	RMSE	MAE
ARIMA(2,1,1)	0.4637	0.3998
ARIMAX(2,1,1) con sol	0.5121	0.4537
LSTM sin sol	0.4799	0.4181
LSTM con sol	0.9709	0.8770

información pierda es el hallazgo que rompe la intuición del trabajo; la lectura es que el canal solar no trae señal mensual y el pronóstico recursivo amplifica el ruido que sí trae.

El bloque RL sí aprende: de nivel azar a retorno voraz ≈ -199 en la semilla principal y ≈ -175 y ≈ -223 en las dos de robustez, con la curva de la Figura 5.

V. CONCLUSIONES

1. La temperatura global se predice en el corto plazo con su propio pasado, pero su subida sostenida no sale de la historia lineal ni de la red: falta el forzante que la empuja.
2. La actividad solar, con su ciclo decenal bien medido, no aporta señal predictiva mensual a la temperatura en este marco. El EDA ya lo había adelantado con la correlación contemporánea nula; P2 y P3 lo confirman en el modelo, con el coeficiente sin significación y con la red multivariada peor. Es una confirmación declarada, no un hallazgo nuevo.
3. El aprendizaje por refuerzo sí resuelve su tarea continua cuando la recompensa guía paso a paso: el péndulo se estabiliza desde cualquier semilla.
4. Reproducibilidad: cuaderno ejecutado de punta a punta con `requirements.txt` pinneado y semillas fijas, figuras exportadas por script aparte a `assets/images/` y entorno con `venv` local; el cuaderno se ejecuta de punta a punta en Colab desde <https://colab.research.google.com/github/JheisonMB/ml/blob/main/series-temporales-prediccion/series-temporales-prediccion.ipynb>.




Figura 4. Observada contra los cuatro pronósticos sobre la prueba.




Figura 5. Retorno por episodio del DQN, media móvil de 20.

APÉNDICE

Fragmentos de Código Clave

```
import kagglehub
from pathlib import Path
sun_dir = Path(kagglehub.dataset_download(
    'gallo33henrique/sunspot-numbers-dataset-17002025'))
```

```
from statsmodels.tsa.stattools import
    adfuller
stat, pvalue, *_ = adfuller(train['land'].
    dropna())
```

```
from statsmodels.tsa.statespace.sarimax
    import SARIMAX
fit = SARIMAX(train['land'], order=(2, 1, 1))
    .fit(dispatch=False)
```

- [6] B. Lim, S. Ö. Arık, N. Loeff, and T. Pfister, "Temporal fusion transformers for interpretable multi-horizon time series forecasting," *International Journal of Forecasting*, vol. 37, no. 4, pp. 1748–1764, 2021.
- [7] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, and D. Hassabis, "Human-level control through deep reinforcement learning," *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.
- [8] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne, Australia: OTexts, 2021, available: <https://otexts.com/fpp3/>.
- [9] gallo33henrique, "Sunspot numbers dataset 1700–2025," [Online]. Available: <https://www.kaggle.com/datasets/gallo33henrique/sunspot-numbers-dataset-17002025>, 2025.
- [10] R. A. Rohde and Z. Hausfather, "The Berkeley Earth Land/Ocean Temperature Record," *Earth System Science Data*, vol. 12, no. 4, pp. 3469–3479, 2020.
- [11] adarshsalukhe, "Global land temperature anomalies 1880–2024," [Online]. Available: <https://www.kaggle.com/datasets/adarshsalukhe/global-land-temperature-anomalies-1880-2024>, 2024.
- [12] D. A. Dickey and W. A. Fuller, "Distribution of the estimators for autoregressive time series with a unit root," *Journal of the American Statistical Association*, vol. 74, no. 366, pp. 427–431, 1979.
- [13] Farama Foundation, "Pendulum: Continuous control environment," [Online]. Available: https://gymnasium.farama.org/environments/classic_control/pendulum/, 2024.
- [14] M. Towers, A. Kwiatkowski, J. Terry, J. U. Balis, G. De Cola, T. Deleu, M. Goulão, A. Kallinteris, M. Krimmel, A. KG, R. Perez-Vicente, A. Pierré, S. Schulhoff, J. J. Tai, H. Tan, and O. G. Younis, "Gymnasium: A standard interface for reinforcement learning environments," *arXiv preprint arXiv:2407.17032*, 2024.

REFERENCIAS

- [1] D. H. Hathaway, "The Solar Cycle," *Living Reviews in Solar Physics*, vol. 12, p. 4, 2015.
- [2] WDC-SILSO, Royal Observatory of Belgium, "SILSO sunspot number data files, monthly mean total sunspot number," [Online]. Available: <https://www.sidc.be/silso/>, 2025.
- [3] Berkeley Earth, "Global land temperature anomalies, monthly land average," [Online]. Available: <https://berkeleyearth.org/data/>, 2024.
- [4] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed. Hoboken, NJ: Wiley, 2015.
- [5] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.