

Series Temporales: ¿La Actividad Solar Ayuda a Predecir la Temperatura Global?

ARIMA, LSTM y DQN sobre Manchas SILSO y Anomalías Berkeley Earth

Jheison Martinez Bolivar
Maestría en Inteligencia Artificial
Universidad de La Salle, Bogotá, Colombia
 jhmartinez07@unisalle.edu.co

Resumen—Este trabajo pregunta si la actividad solar aporta señal predictiva a la temperatura global mensual. Sobre el marco común 1880–2025 (1751 meses, sin nulos ni duplicados) se compara la anomalía terrestre `land` de Berkeley Earth contra el conteo de manchas SILSO como variable exógena, con corte temporal en 2001 (entrenamiento $n = 1452$, prueba $n = 299$). El ARIMA(2,1,1) elegido por AIC obtiene $RMSE = 0,4637$ en la prueba; añadir el sol lo empeora ($RMSE = 0,5121$, coeficiente prácticamente cero). La LSTM univariada empató al ARIMA ($RMSE = 0,4799$) y la multivariada pierde en las tres semillas ($RMSE$ entre 0.50 y 1.05), así que la hipótesis solar queda enterrada por las dos vías. En bloque aparte, un DQN con acciones discretizadas aprende a estabilizar el péndulo de `Pendulum-v1` (retorno voraz ≈ -214 contra ≈ -1250 del azar, estable en tres semillas). El cuaderno con la implementación completa se ejecuta en Colab desde https://colab.research.google.com/github/JheisonMB/ml/blob/main/series-temporales-prediccion/series_temporales_prediccion.ipynb.

I. INTRODUCCIÓN

EL Sol impone un ciclo de unos once años sobre su propia actividad, visible en el conteo de manchas, y el clima terrestre guarda memoria de largo plazo en sus anomalías de temperatura [1], [2]. La pregunta de si el primero ayuda a predecir la segunda es anterior al aprendizaje automático y sigue abierta en su forma predictiva: no si el Sol causa el clima, sino si ver las manchas reduce el error de pronóstico de la temperatura.

Este trabajo la convierte en una comparación cerrada: la misma serie, el mismo corte temporal, los mismos errores, con y sin la variable solar. Del lado estadístico, ARIMA y su extensión con exógena ARIMAX [3]; del lado aprendido, redes LSTM univariadas y multivariadas [4]. En bloque independiente, y porque la actividad también lo pide, un agente DQN [5] sobre un entorno de control continuo. La metodología de series sigue la referencia canónica de pronóstico [6].

II. DATOS Y PREPROCESAMIENTO

II-A. Selección de los Conjuntos de Datos

Se usan dos fuentes con cobertura mensual solapada desde 1880. Las manchas provienen del conteo mensual total SILSO

v2.0 (archivo `SN_m_tot_V2.0.csv`, sin encabezado y con separador `;`), cuya documentación oficial describe las siete columnas [1], [7]. La temperatura proviene de las anomalías mensuales Berkeley Earth (columnas `time`, `station`, `land`), donde cada valor es la desviación del mes respecto a su referencia climática [2], [8]. Una anomalía no es la temperatura del termómetro: $+0,5$ significa medio grado por encima de lo normal para ese mes.

Como protagonista se fija `land` (solo tierra): trae menos dispersión que la combinada `station` ($\sigma = 0,41$ contra $0,52$) y es la serie limpia del conjunto; su correlación mensual contemporánea con las manchas es prácticamente cero en ambas ($\approx 0,02$), así que un vínculo instantáneo queda descartado desde el EDA.

II-B. Marco Común y Limpieza

El tiempo decimal de Berkeley Earth se convierte a mes calendario por truncamiento, no por redondeo: redondear salta febrero y duplica abril, defecto que se detectó por 585 fechas duplicadas y se corrigió antes de seguir. El marco común 1880-01 a 2025-11 queda con $n = 1751$ meses contiguos, cero nulos y cero duplicados. La Figura 1 muestra las dos series en nivel.

La descomposición aditiva de `land` con período 12 (Figura 2) muestra una tendencia que recorre más de un grado y un componente anual mínimo ($\pm 0,03^\circ\text{C}$): la anomalía descuenta las estaciones al medirse contra su propio mes, y la lectura estacional que sobrevive (marzos y octubres altos, junios bajos) no corresponde a estaciones de ningún hemisferio. La dispersión por década crece en las décadas recientes.

El ciclo solar se caracteriza pico a pico sobre la suavizada de 13 meses que usa el SILSO, exigiendo casi una década entre máximos porque cada ciclo trae picos dobles: 14 máximos con intervalos alrededor de la decena de años (pico espectral en ≈ 125 meses). La Figura 3 los marca.

El corte es estrictamente temporal: entrenamiento 1880–2000 ($n = 1452$) y prueba 2001 en adelante ($n = 299$), sin barajar. La validación de la LSTM sale de dentro del entrenamiento (1991–2000), sin tocar la prueba.




Figura 1. Anomalía terrestre land (arriba) y manchas solares mensuales (abajo), 1880–2025.




Figura 2. Tendencia por promedio móvil centrado de 12 meses y perfil estacional de 12 meses de land.

III. METODOLOGÍA

III-A. ARIMA y ARIMAX

El test ADF [9] sobre el entreno no rechaza raíz unitaria en nivel ($p = 0,42$) y sí en primera diferencia ($p \approx 0$), de modo que $d = 1$. La ACF de la diferencia corta en el rezago uno y la PACF decae gradualmente, firma de media móvil de orden uno; el AIC sobre el entreno elige ARIMA(2,1,1) frente a sus vecinos. El modelo pronostica como

$$\Delta y_t = c + \phi_1 \Delta y_{t-1} + \phi_2 \Delta y_{t-2} + \theta_1 \varepsilon_{t-1} + \varepsilon_t, \quad (1)$$

y el ARIMAX añade la mancha contemporánea como regresor exógeno con el mismo orden y el mismo corte, de modo que P2 de modo que P2 compara con sol contra sin sol.

III-B. LSTM Univariada y Multivariada

La celda LSTM [4] decide qué olvidar, qué guardar y qué mostrar mediante sus compuertas:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t, \quad (2)$$

donde f_t e i_t son las compuertas de olvido y entrada. La red (LSTM de 32 unidades más capa densa) ve ventanas de 24




Figura 3. Manchas solares con los 14 máximos del ciclo sobre la serie suavizada.

Cuadro I
ERROR SOBRE LA PRUEBA 2001 EN ADELANTE ($n = 299$).

Modelo	RMSE	MAE
ARIMA(2,1,1)	0.4637	0.3998
ARIMAX(2,1,1) con sol	0.5121	0.4537
LSTM sin sol	0.4799	0.4181
LSTM con sol	0.9709	0.8770

meses y pronostica la prueba de forma recursiva sin mirar sus datos; la versión multivariada recibe además las manchas futuras observadas, como exógena que es. Misma arquitectura, misma semilla, mismas ventanas: P3 es el *ablation* que P2 dejó pendiente, y se repite con tres semillas porque el número exacto baila entre corridas aun con igual semilla (no-determinismo de GPU).

III-C. DQN sobre el Péndulo

En `Pendulum-v1` [10] el torque continuo se discretiza en cinco empujones y la red Q minimiza

$$L = \mathbb{E} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right], \quad (3)$$

con caja de recuerdos, red objetivo congelada y ε decreciente durante 300 episodios. El listón es el agente al azar (≈ -1 250 de retorno medio).

IV. RESULTADOS Y DISCUSIÓN

La Tabla I resume la prueba y la Figura 4 la dibuja. P1: el ARIMA se predice con el propio pasado pero su pronóstico de horizonte largo se queda plano y no acompaña la subida (RMSE = 0,4637). P2: el sol no aporta señal, con coeficiente prácticamente cero y error mayor (RMSE = 0,5121). P3: la LSTM sin sol empata al ARIMA (RMSE = 0,4799) y con sol pierde en las tres semillas (0,50–1,05): la hipótesis solar queda enterrada por las dos vías. Que la red con más información pierda es el hallazgo que rompe la intuición del trabajo; la lectura es que el canal solar no trae señal mensual y el pronóstico recursivo amplifica el ruido que sí trae.

El bloque RL sí aprende: de nivel azar a retorno voraz ≈ -206 en la semilla principal y ≈ -214 – -222 en las dos de robustez, con la curva de la Figura 5.

V. CONCLUSIONES

1. La temperatura global se predice en el corto plazo con su propio pasado, pero su subida sostenida no sale de la historia lineal ni de la red: falta el forzante que la empuja.
2. La actividad solar, con su ciclo decenal bien medido, no aporta señal predictiva mensual a la temperatura en este marco; es un resultado negativo documentado, no una hipótesis sin probar.
3. El aprendizaje por refuerzo sí resuelve su tarea continua cuando la recompensa guía paso a paso: el péndulo se estabiliza desde cualquier semilla.
4. Reproducibilidad: cuaderno ejecutado de punta a punta con `requirements.txt` pinneado y semillas fijas, figuras exportadas por script aparte a `assets/images/` y entorno con `venv` local; el cuaderno se ejecuta de punta a punta en Colab desde https://colab.research.google.com/github/JheisonMB/ml/blob/main/series-temporales-prediccion/series_temporales_prediccion.ipynb.

APÉNDICE

Fragmentos de Código Clave

```
import kagglehub
from pathlib import Path
sun_dir = Path(kagglehub.dataset_download(
    'gallo33henrique/sunspot-numbers-dataset-17002025'))
```

```
from statsmodels.tsa.stattools import
adfuller
stat, pvalue, *_ = adfuller(train['land'].
    dropna())
```

```
from statsmodels.tsa.statespace.sarimax
import SARIMAX
fit = SARIMAX(train['land'], order=(2, 1, 1))
    .fit(dispatch=False)
```




Figura 4. Observada contra los cuatro pronósticos sobre la prueba.




Figura 5. Retorno por episodio del DQN, media móvil de 20.

REFERENCIAS

- [1] WDC-SILSO, Royal Observatory of Belgium, “SILSO sunspot number data files, monthly mean total sunspot number,” [Online]. Available: <https://www.sidc.be/silso/>, 2025.
- [2] Berkeley Earth, “Global land temperature anomalies, monthly land average,” [Online]. Available: <https://berkeleyearth.org/data/>, 2024.
- [3] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed. Hoboken, NJ: Wiley, 2015.
- [4] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [5] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, and D. Hassabis, “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.
- [6] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. OTexts, 2021, available: <https://otexts.com/fpp3/>.
- [7] WDC-SILSO, “Sunspot numbers dataset 1700–2025,” [Online]. Available: <https://www.kaggle.com/datasets/gallo33henrique/sunspot-numbers-dataset-17002025>, 2025.
- [8] Berkeley Earth, “Global land temperature anomalies 1880–2024,” [Online]. Available: <https://www.kaggle.com/datasets/adarshsalukhe/global-land-temperature-anomalies-1880-2024>, 2024.
- [9] D. A. Dickey and W. A. Fuller, “Distribution of the estimators for autoregressive time series with a unit root,” *Journal of the American Statistical Association*, vol. 74, no. 366, pp. 427–431, 1979.
- [10] Farama Foundation, “Gymnasium: An API standard for single-agent reinforcement learning environments, Pendulum-v1,” [Online]. Available: <https://gymnasium.farama.org/>, 2024.